國立陽明交通大學管理科學系

專題研究報告

多代理人立場交換辯論機制

應用於投資決策

Multi-Agent Role-Switching Debate

for Investment Decision-Making

學　　生：　黃岳振

指導教授：　林斯寅 教授

中華民國一一五年十月

摘　要

投資時要同時看股價走勢、公司財報、新聞氣氛和整體經濟狀況，而這些資訊常常互相矛盾。「多代理人辯論」是讓多個 AI 角色分別扮演看多與看空，互相挑毛病，最後由一位裁決者做決定。但只是給 AI 不同的角色，並不代表它們真的會有不同的想法。本研究的核心是「自我反駁式立場交換」：讓 AI 先主張一個立場，再換邊反駁自己，最後回到原本立場整理結論。本研究的目的是比較不同辯論設計之間的差異，檢驗立場交換、模型異質性與領域分工等機制能否提升辯論品質與決策表現，而非建構能勝過市場的交易策略。

本研究規劃三個問題：第一，整套立場交換辯論（D）比起「各守原立場」的整套固定立場辯論（C），有沒有額外的好處；第二，辯論的雙方如果使用不同的 AI 模型，這個好處會不會改變；第三，把四類資訊分給四組專長不同的辯論者處理，結果與成本會不會更好。第一個問題比較整套立場交換流程與整套固定立場流程（D 同時改變立場交換、隔離對手、強制引用與驗證重試，不能單獨歸因於立場交換）；第二個問題檢驗這個結果是否取決於模型組合；第三個問題則是另一個系統層面的條件（資訊分工），與立場交換沒有直接關係，納入是因為它同樣是本系統目前尚未檢驗的設計選項。**本報告已完成第一個問題；第二、第三個問題目前只完成研究設計，尚未執行，因此本報告不提供它們的結果。**

研究使用九檔美國大型股在 2021 至 2025 年間的 180 個季度案例，每個案例只使用分析日以前已公開的資料，並以資料快照與稽核紀錄控制主要輸入。主要評估指標是 60 個交易日後的方向準確率（猜對漲跌的比例）與年化 Sharpe 比率（每承擔一單位風險能換到多少報酬），另外也看報酬、最大虧損、雙方意見分歧與運算資源。現有版本與原始輸出的保存仍有缺漏，因此本研究的結果只適用於指定樣本與流程，並非可完全重現的確認性檢驗。

第一個問題的 180 案比較結果如下：D 的準確率（55.0%）與 Sharpe（0.54）沒有比 C（58.3%、0.59）更高，也就是沒有找到 D 比 C 好的顯著證據。此外，C、D 的準確率都低於「一律看多」（所有案例都預測上漲）的 62.2%，四組（C、D 與補充對照的 A、B）的 Sharpe 也都低於同配置買進持有（持有同一批標的、不依預測調整）的 1.01（準確率相對「一律看多」的事後配對檢定也不顯著；Sharpe 相對買進持有則尚未檢定）。要注意的是，D 同時改變了交

換立場、隔離對手、強制引用自己原文與驗證重試，所以結果不能歸因於單一的「立場交換」。此外，RQ1 屬於已見樣本的回溯比較：同一批樣本曾用於試跑與規則調整，因此不是事前確認性檢驗。

關鍵詞：大型語言模型、多代理人辯論、立場交換、模型異質性、領域專業化、投資決策
JEL 分類碼：G11、G17、C53

Multi-Agent Role-Switching Debate for Investment Decision-Making

Abstract

Investment decisions require the integration of technical, fundamental, news-sentiment and macroeconomic evidence, which may conflict with one another. Multi-agent debate uses opposing views and adjudication to examine arguments, yet role differences do not necessarily produce useful reasoning diversity. This study centers on self-rebuttal role-switching and plans three research questions: (RQ1) whether the full role-switching debate procedure (D) adds value over the full fixed-role debate procedure (C); (RQ2) whether model composition changes this effect; and (RQ3) whether domain-specialized decision-making improves performance and cost effectiveness. RQ1 addresses role-switching itself; RQ2 asks whether that result depends on model composition; RQ3 asks about a separate system-level condition (information division of labor) that is not directly about role-switching. The aim is to compare debate designs, not to build a trading strategy that beats the market. **This report completes RQ1 only; RQ2 and RQ3 are planned designs that have not been run, and no results are reported for them.**

The study uses 180 quarterly cases of nine U.S. stocks in 2021–2025, integrating four financial information domains under point-in-time data boundaries, immutable snapshots, evidence identifiers and audit trails. The primary evaluation metrics are 60-trading-day directional accuracy and annualized Sharpe ratio, supplemented by return, drawdown, disagreement and inference-resource measures.

For RQ1, D did not outperform C in directional accuracy (55.0% vs. 58.3%) or annualized Sharpe ratio (0.54 vs. 0.59), and no significant evidence favoring D was obtained. Point estimates for both C and D also fall below an always-buy benchmark (predicting that every case rises) in accuracy (62.2%) and below a buy-and-hold reference in Sharpe ratio (1.01); a post hoc paired test of accuracy against always-buy was not significant, and the Sharpe comparison was not tested. Because D bundles role-switching, opponent isolation, forced self-quotation and validation retries, the result cannot be attributed to role-switching alone. Because the same sample had been used for pilot work and rule revisions, this is a retrospective comparison under locked rules rather than a confirmatory test.

Keywords: large language models, multi-agent debate, role switching, model heterogeneity, domain specialization, investment decisions
JEL Codes: G11, G17, C53

目　次

第一章　引言 1
第一節　研究背景 1
第二節　研究動機 2
第三節　研究目的 3
第四節　研究問題 3
第五節　研究範圍 4

第二章　文獻探討 7
第一節　多代理人辯論 7
第二節　角色交換與自我反駁 7
第三節　多代理人系統中的模型異質性 8
第四節　金融領域的語言模型與投資代理人 9
第五節　領域專業化與任務拆分 10
第六節　裁決、整合與驗證 10
第七節　偷看未來的問題與金融評估 11
第八節　文獻小結與研究缺口 11

第三章　研究方法 13
第一節　研究架構 13
第二節　資料收集 15
第三節　實驗設計 16
第四節　工具及設備 28

第四章　系統設計與實作 29
第一節　系統架構 29
第二節　功能模組 29
第三節　介面設計 31
第四節　實作流程與驗證 32
第五節　實作上的挑戰 33

第五章　結果與討論 35
第一節　既有實驗規則下的機制比較 35

第二節 探索性的跨模型分析與前導診斷 39
第三節 討論 41
第四節 研究限制 42

第六章 結論與建議 45
第一節 研究發現與對研究問題的回應 45
第二節 應用與價值 46
第三節 未來展望 46

參考文獻 48

表　次

表 1-1　研究範圍 5
表 1-2　研究狀態 6
表 3-1　資料來源與處理方式 15
表 3-2　四組決策機制 18
表 3-3　立場交換辯論的三輪流程 19
表 3-4　主要設計選擇及其用途 20
表 3-5　不同模型的 D 組中，模型身分與立場的對應（模型不會隨立場一起交換） 22
表 3-6　RQ3 預定流程（設計階段，尚未執行） 23
表 3-7　三個研究問題的比較設計 27
表 3-8　工具及設備 28
表 4-1　功能模組的實作狀態 29
表 5-1　四組績效（180 案，60 個交易日，已扣除交易成本） 35
表 5-2　立場交換辯論（D）的配對檢定（60 個交易日） 35
表 5-3　案例一：INTC 2024-03-31 的辯論與裁決（60 日實際報酬 −30.5%） 37
表 5-4　qwen3:32b 的方向混淆分布（60 日，候選決策） 39
表 5-5　跨模型比較：方向準確率（60 日、候選決策、有出手的案例） 40
表 5-6　可重現性紀錄的現況 44

圖　次

圖 3-1　研究概念架構。三個分支共用同樣的資料、候選決策與評估方式；實線為已完成，虛線為設計階段（尚未執行）；RQ3 為平行的架構延伸，不檢驗立場交換。 14

圖 4-1　網頁介面的資料流向圖（一個已完成的案例）。由左至右依序為資料來源、資料代理人、資料快照、研究代理人、中立報告、四組決策、守門員、回測與統計。 32

第一章　引言

第一節　研究背景

一、金融資訊整合與大型語言模型

做投資決策時，要同時參考股價走勢（技術面）、公司財報（基本面）、新聞氣氛（情緒面）和整體經濟狀況（總體經濟面）。這些資訊更新的速度、呈現的形式，甚至指向的方向都可能不一樣。大型語言模型（例如 ChatGPT 這類 AI）可以幫忙閱讀財報、新聞和市場資料，已有不少研究把大型語言模型用在金融文字分析與投資分析 (Lopez-Lira and Tang, 2023; Liu et al., 2023)，預訓練語言模型（如 FinBERT）也早已用於金融文字 (Araci, 2019)。不過，「把資訊整理好」和「預測未來報酬」是兩件不同的事；AI 的說明寫得有條有理，不代表它真的能預測股價。

二、多代理人辯論與立場交換

多代理人辯論，是讓多個 AI 角色輪流提出論點、批評對方、修正自己 (Du et al., 2023; Liang et al., 2023)。金融領域的 AI 系統也常把工作分成分析與交易等角色，其中 TradingAgents 設有看多與看空兩類研究員 (Xiao et al., 2024; Zhang et al., 2024)。但辯論好不好用，要看用什麼模型、怎麼互動、怎麼裁決，在其測試的問答任務上，並不一定比單一模型或「多問幾次再投票」更好 (Smit et al., 2023; Zhang et al., 2025)。因此，辯論流程怎麼設計，本身就是值得研究的問題。

本研究主要比較兩種辯論方式。C 組是「固定立場辯論」：看多方一直站在看多，看空方一直站在看空。D 組是「自我反駁式立場交換」：第二輪時，每個角色只看自己第一輪寫的內容，然後換到相反立場，引用並反駁自己原本的主張；第三輪再回到原本立場，把剛剛找到的反面證據整理進結論。本研究想了解，這種「逼自己重新檢查證據」的做法，有沒有額外的價值，並進一步看它會不會受到模型組合與資訊分工方式的影響。

本研究另設兩個補充對照組。A 組是「單次判斷」：同一份資料只問模型一次。B 組是「獨立投票」：同一提示獨立取樣 7 次後以多數決決定，是

自我一致性 (Wang et al., 2023) 的簡化版。A、B 代表不使用代理人架構的一般語言模型用法；角色分工、反思與長期記憶則屬於代理人架構的組成 (Shinn et al., 2023; Park et al., 2023; Yu et al., 2024)，所以只有 C、D 有長期記憶。主要比較是 C 對 D，兩者都有記憶，條件對等；A、B 對 C、D 的比較同時混合了「有無辯論」與「有無記憶」兩項差異，只作為參考，並列入研究限制。

第二節　研究動機

一、自我反駁機制有沒有額外價值

多代理人辯論到底有沒有用，目前仍有爭議。有些研究發現辯論能提高推理的正確率 (Du et al., 2023)，但也有研究發現，在其測試的問答任務上，辯論不一定比「同一個問題問多次再投票」好，而且辯論的效果常被高估 (Smit et al., 2023; Zhang et al., 2025)。辯論有一個常見的問題：角色會「死守立場」，只會加強自己的論點，不回應對方的證據 (Liang et al., 2023)。立場交換就是為了緩和這個問題而提出的 (Liu et al., 2025; Chowdhury et al., 2026)。這些研究讓我們有理由期待立場交換可能有用，但它們處理的是問答或事實查核，和預測未來股價報酬不同。所以本研究直接拿 C、D 兩種流程，在相同資料、相同預定決策呼叫次數（C、D 各 7 次，見第三章）下比較。

另外，股票回測很容易失真。AI 模型可能在訓練時就已經看過回測期間之後的股價走勢，等於「偷看答案」(Glasserman and Lin, 2023; Kong et al., 2026)；辯論組通常也比單次判斷多用好幾倍的模型呼叫次數 (Smit et al., 2023; Chowdhury et al., 2026)。因此，本專題希望在控制這些問題的前提下，檢驗立場交換在投資情境裡是否真的有用。

除了 RQ1，本研究另有兩個延伸問題。它們的動機來自文獻與系統現況，而不是 RQ1 結果已證實的原因（RQ1 未發現 D 優於 C，見第五章）：其一，辯論雙方由同一個模型擔任；其二，四類資訊合併處理。以下兩項是**候選假說**。RQ2 檢驗前者是否改變 D 相對於 C 的差異；RQ3 檢驗後者所對應的整套領域化架構（不含立場交換）。

二、同一個模型扮演雙方，想法可能不夠多元

看多（Bull）與看空（Bear）兩個角色雖然被要求主張相反的立場，但如果背後是同一個 AI 模型，它們可能有相同的知識盲點、相同的推理習慣，也會犯相同的錯。角色不同，不保證想法真的不同；有研究主張換用不同的模型有助於互補 (Zhang et al., 2025; Wang et al., 2024)，但這是否適用於本研究，還需要檢驗。另一方面，不同模型的能力、訓練資料與寫作風格本來就不一樣，所以換了模型之後績效出現差異，不能直接說是「模型不同」造成的。

三、通才組把資訊集中處理，專才組分工處理

目前系統已有四個研究代理人，負責整理四類資訊，但真正做判斷的仍只有同一組看多與看空。技術、基本、新聞情緒與總體經濟這四類證據，更新速度和訊號性質各不相同；全部合在一起處理，可能讓某一類資訊的反面證據被稀釋，也可能讓模型一次要讀的內容太多。這是候選假說，並非已被 RQ1 的結果證實的原因。RQ3 打算讓四類資訊各自有自己的多空辯論，再由上層整合，然後評估這樣做的好處、意見衝突與額外成本。

第三節　研究目的

本研究的目的是比較不同辯論設計之間的差異，檢驗立場交換、模型異質性與領域分工等機制能否提升辯論品質與決策表現，而非建構能勝過市場的交易策略。具體而言，本研究檢驗自我反駁式立場交換相較於固定立場辯論有沒有額外價值；檢驗模型組合是否改變 D 相對於 C 的差異（結果僅適用於指定的模型組合）；並檢驗領域內辯論加上上層整合，相對於通才（Generalist）做法的績效與成本。這些都是辯論設計之間的受控比較，不以策略能否勝過市場為前提。

第四節　研究問題

RQ1 是本研究最初的核心問題。RQ2、RQ3 是 RQ1 完成後提出的延伸問題，分別檢驗模型組合與領域分工。RQ1 比較整套立場交換流程與整套固定立場流程，不單獨辨識立場交換的作用；RQ2 問這個結果是否取決於模型組合；RQ3 轉而問另一個系統層面的條件（資訊分工），與立場交換無直接關係，

納入是因為它同樣是本系統目前尚未檢驗的設計選項。

一、RQ1：原始機制

在相同的案例資料與相同的預定決策呼叫次數（C、D 各 7 次，見第三章）下，自我反駁式立場交換辯論（D）的 60 日方向準確率與年化 Sharpe，是否高於固定立場辯論（C）？

二、RQ2：模型異質性

當看多與看空代理人由不同的基礎模型擔任時，自我反駁式立場交換辯論（D）相對於固定立場辯論（C）的投資決策效果，是否會改變？

三、RQ3：領域專業化辯論

原本是把四類金融資訊合併後，交給同一組多空代理人辯論。若改為讓技術面、基本面、情緒面與總經面代理人，各自在自己的資訊範圍內進行多空辯論，再由上層整合機制做出最終決策，方向準確率與風險調整後績效是否會更好？

RQ1 與 RQ2 構成主要研究線：先比較整套 C、D 流程，再檢驗模型組合是否改變兩者差異。RQ3 是平行的系統架構延伸，檢驗資訊分工與額外運算成本的整體取捨；它比較的是「整套領域化架構」，結論不稱為單純的分工效果，也不直接檢驗立場交換。

第五節　研究範圍

一、樣本與資料時間邊界

本專題是投資決策輔助的研究與系統原型，不是會自動下單的交易系統。研究範圍整理於表 1-1。

表 1-1 研究範圍

項目	說明
標的與期間	九檔美國大型股；2021 至 2025 年每季取一個分析日，共 180 個案例
資料	技術面、基本面、情緒面（新聞標題）與總經面；只使用分析日以前已經公開的資料
決策輸出	買進、持有或賣出，並附上預期報酬、信心度、理由、引用的證據與風險
評估	60 個交易日後的方向準確率與 Sharpe 比率；30 與 90 日用來檢查結果穩不穩

二、預測期間與決策層

本研究維持九檔股票、20 個季末、共 180 個「股票 × 日期」案例，預測期間為 60 個交易日。C、D 兩組的候選決策（守門員處理之前的判斷）只能在買進與賣出之間選一個；之後的「守門員」(Gatekeeper）會在候選決策之後檢查證據與風險，必要時把決策降為持有或不交易，詳見第三章。A（單次判斷)、B（七次獨立投票）兩組允許選持有，只作為補充對照；兩組沒有長期記憶，與 C、D 的比較同時混合有無辯論與有無記憶，結果僅供參考（見第五章研究限制)。主要分析使用守門員之前的候選決策；經守門員處理後的實際結果，另外作為敏感性分析。以月（約 20 個交易日）為單位的比較屬於未來研究，本研究的季度樣本不變。

三、研究狀態與證據界線

各部分目前的進度整理於表 1-2。其中 v3-1002.3 指本研究鎖定的季度實驗規則版本。RQ1 屬於已見樣本的回溯比較：同一批樣本曾用於試跑與規則調整，因此不是事前確認性檢驗。RQ2、RQ3 與月度設計都還只是設計，設計中預期的好處不能當成已有的結果。

表 1-2 研究狀態

項目	狀態	能說明到什麼程度
RQ1：D 對 C（qwen3:32b (Yang et al., 2025)，季度實驗規則 v3-1002.3）	已完成 180 案	這是回溯比較（定義見上）。沒有找到 D 優於 C 的顯著證據，但這不等於兩者一樣好
Gemini 3 Flash 同批比較	已報告（探索性）	整套系統換成同一個別的模型，不是 RQ2；用的還是同一批案例，不算獨立重做
RQ2：模型組成	設計階段，未執行	比較方式與配置規則見第三章第三節第七項；尚無結果
RQ3：領域分工	設計階段，未執行	流程與資源比較見第三章第三節第八項；尚無結果
月度／20 日設定	未執行	另外獨立設計，不併入這 180 個季度案例

第二章　文獻探討

第一節　多代理人辯論

一、辯論與「多次取樣投票」的公平比較

Du et al. (2023) 讓多個模型實例進行多輪辯論後收斂出答案，使推理與事實正確性變好。Liang et al. (2023) 指出模型自我反省時容易死守原本的答案，因此用辯論來鼓勵多元思考。但另一方面，Smit et al. (2023) 比較了多種辯論策略，發現多代理人辯論不一定比「自我一致性」等其他方法穩定地好，而且對設定很敏感；Zhang et al. (2025) 則認為目前的評估常高估辯論的效果，建議重新思考評估方式，並改用不同的模型。「自我一致性」(Wang et al., 2023) 是指同一個問題問多次、再用多數決選答案。這能讓結果更穩定，也是比較辯論效果時必要的對照組 (Smit et al., 2023; Zhang et al., 2025)；本研究的「獨立投票組」（B 組）是這個做法的簡化版：同一提示獨立取樣 7 次（對齊 C、D 的決策呼叫次數，而非自我一致性原文的取樣數），再對買進、持有、賣出三類做多數決，沒有推理路徑的邊際化。因此，本研究把重點放在流程可追蹤、比較公平（模型呼叫次數對齊），而不是先假設辯論一定比較準。

第二節　角色交換與自我反駁

一、為什麼可能有效，又為什麼可能無效

Liu et al. (2025) 提出「會考慮不確定性的角色交換辯論」：兩位辯論者先各自給出初步答案並互相質問，辯論到一半時交換角色、改為論證相反立場，然後各自回報信心與不確定性，最後由另一個裁判模型決定。在 OpenBookQA（問答題庫）上，他們的消融實驗（把某個步驟拿掉看結果變化）顯示，角色交換與回報不確定性兩個階段都有貢獻。Chowdhury et al. (2026) 的 PROCLAIM 以法庭角色（原告、辯護、法官）搭配逐步檢索來查核主張，並用角色交換檢查答案是否一致；其消融結果顯示角色交換約使準確率提高 4.2 個百分點，但整體 token 用量約為標準多代理人辯論的 11 倍。Chen et al. (2026) 的多人格思考則讓相反的人格與中立觀點反覆對話，使偏誤被說出來並被修正。這

些研究支持「從相反立場重新想一次」這個想法，但它們都不是投資決策，而且其中 PROCLAIM 的好處是靠大幅增加成本換來的，這也說明為什麼比較時必須讓模型呼叫次數相同。本研究因此採用「看多、看空、裁決者」三方架構（多空角色分工亦見 Xiao et al., 2024），並讓獨立投票組與兩個辯論組的決策呼叫次數對齊（單次判斷組為基準）。

機制的動機與可能失效的情況。 Lord et al. (1984) 的人類社會判斷實驗指出，主動考慮「與自己原本信念相反的可能性」，可以減少特定的判斷偏誤。Herzog and Hertwig (2009) 則在其估計任務上發現，人在刻意產生與自己第一個估計不同的第二個估計後，把兩者平均能改善個人判斷，這比較接近「自己產生反方想法」的做法。本研究據此提出假說：要求 AI 引用並反駁自己的論點，也許能挖出先前被忽略的反面證據，讓裁決者更平衡地衡量證據。不過，這個推論是從人類實驗延伸到 AI 預測股價，仍需實際檢驗；論述寫得更完整，也不一定代表預測得更準。Huang et al. (2024) 發現，沒有外部回饋的自我修正，在其測試的推理題上可能沒效果，甚至讓表現變差。本研究的 D 組與這類完全沒有外部回饋的自我修正不完全相同，因為它要求引用並驗證自己的原文與證據。如果模型共享相同的錯誤、輸入資訊本身缺乏預測力，或市場雜訊太大，自我反駁也可能只是改變說法，績效並沒有進步。

第三節　多代理人系統中的模型異質性

一、模型不同、能力不同與模型偏好

Zhang et al. (2025) 檢驗了多代理人辯論的評估方式，並主張使用不同的底層模型（模型異質性）有益，讓我們有理由研究不同模型一起推理的效果。但他們的基準測試結果，不能直接套用到金融未來報酬預測，也不能直接套用到本研究的自我反駁規則。RQ2 要做的，是在同一場辯論裡同時放進 M1、M2 兩種模型；這和「整套系統都換成另一個模型」不同，後者仍然是單一模型的做法（homogeneous setting）。模型的能力高低、偏好、裁決者對某種文風的偏愛 (Zheng et al., 2023)，以及不同模型犯錯的相關性，都必須分開檢查。

Wang et al. (2024) 的 Mixture-of-Agents 把多個模型的輸出一層一層地整合，並比較「同一模型重複生成」與「多個模型各自提案」的差別。該研究的架構也把「提出方案」與「整合方案」分成不同角色。本研究推測，同一個模型放在流程的不同位置，適用程度可能不同，但這是本研究的推測，並非該文的結論。本研究據此把模型組合當成實驗要操弄的因素，並固定裁決者；不過，該研究是一般語言任務，結果不等於不同模型的金融辯論就有效，也不能排除只是模型能力有差距。

第四節　金融領域的語言模型與投資代理人

一、金融文字分析與代理人流程

Lopez-Lira and Tang (2023) 在其樣本與設定中發現，大型語言模型對金融新聞標題的判讀，含有與後續報酬相關的訊息。FinBERT (Araci, 2019) 與 FinGPT (Liu et al., 2023) 提供了金融文字處理的方法，FNSPID (Dong et al., 2024) 則提供有時間戳記的新聞資料。這些研究說明了資訊整理可能有用，但並不能直接證明任何一種辯論流程有額外價值。

TradingAgents (Xiao et al., 2024) 與 StockAgent (Zhang et al., 2024) 把 AI 分工與交易決策放在回測或模擬環境中檢驗；它們的研究對象是整套代理人系統，和本研究「先固定案例輸入，再比較 D、C」的做法不同。Glasserman and Lin (2023) 對「偷看未來」風險的分析，以及 Huang et al. (2024) 對「沒有外部回饋的自我修正」的謹慎結果，都提醒研究者：推理流暢、模擬績效漂亮，並不能單獨證明模型有可用的預測能力。因此，本研究把缺口限定為：在預定決策呼叫次數相同、資料時間邊界可以被查核的條件下，檢查「重新審視既有證據」的自我反駁流程，能不能改善方向準確率與風險調整後績效；而不是單純把現成的辯論方法搬到金融領域。

記憶與反思是語言模型代理人架構常見的組成。Reflexion 把口頭反思存入記憶，供之後的嘗試參考 (Shinn et al., 2023)；Generative Agents 的架構含記憶串流、反思與規劃 (Park et al., 2023)；FinMem 則是針對金融交易的代理人，設有分層長期記憶與決策模組 (Yu et al., 2024)。本研究據此把角色分工、反思與長期記憶視為代理人架構的組成：C、D 屬於這一類，因此有長期記憶；A、B 代表不使用代理人架構的一般語言模型用法，不讀記憶。這些文獻說明記憶是常見的設計，並沒有證明它會改善本研究的預測；TradingAgents 在

本研究中只用來說明多空角色分工，不用來支持記憶設計。

近期也已有研究直接檢查多代理人辯論的論證品質與金融績效關係。Huang et al. (2026) 在歷史市場模擬中發現，較高的整體論證品質未必伴隨較高的 Sharpe 或總報酬，顯示「論證看起來更好」與「經濟結果更好」必須分開評估。該研究著重投資組合配置、論證品質與分歧維持；本研究則比較固定立場與自我反駁式立場交換的整套流程，兩者的研究對象不同，但都支持以金融績效而非文字品質作為主要判準。

第五節　領域專業化與任務拆分

一、「整理資料」分工與「做決策」分工的差別

TradingAgents 與 StockAgent 提供了金融代理人工作流程的背景 (Xiao et al., 2024; Zhang et al., 2024)。FinRobot 把金融任務拆給不同的專業代理人，並用分層流程處理，是金融問題拆解與工具串接的一個例子 (Yang et al., 2024)；但它並沒有提供本研究「四領域多空辯論 vs. 通才架構」的受控績效比較。

Chen et al. (2023) 的 AgentVerse 把流程分成專家配置、協作決策、執行與評估，並討論水平與垂直兩種協作結構，說明代理人怎麼分工、怎麼溝通，會共同影響決策的過程。因此，RQ3 把專業化從「資料整理層」延伸到「領域內推理」與「上層整合」。要說明的是，把資訊切成四個領域，是本研究自己的設計選擇，並不是既有研究證明過的最佳架構。

把資訊按領域切開，可能保留每個領域的反面證據，但也可能遺失跨領域的關聯、增加摘要時壓縮資訊的損失，並帶來整合時的誤差。與其只用「模型一次讀不下太多內容」來解釋分工，本研究更關心：專業化要不要進到「決策推理」這一層？並用績效、證據使用與推論資源，來評估其中的得失。

第六節　裁決、整合與驗證

一、產生論證、上層整合與證據驗證

Mixture-of-Agents 把「提出方案」與「上層整合」分開 (Wang et al., 2024)，提供了不同角色分別負責論證與整合的架構參考。Zheng et al. (2023) 指出，用

大型語言模型當裁判時，可能出現偏好排在前面的答案、偏好較長的答案、偏好自己產生的答案等偏誤，所以裁決時輸入的順序、長度與模型標籤都需要控制。不過，該研究評估的是「回答品質」，並不能直接證明本研究的投資裁決者有預測能力。

本研究據此把「產生論證」、「整合決策」與「驗證證據」分成三個可以被查核的步驟。裁決者（Judge）或最終整合者（Final Aggregator）綜合各方論點，決定方向；守門員（Gatekeeper）則檢查證據是否真的存在、資料是否足夠，以及風險是否過高。守門員是本系統自己的驗證設計，本研究不以一般的 AI 裁判文獻，來說明它能改善投資績效。同樣地，候選決策只能在買進與賣出之間選一個（強制下注）也是本系統沿用的設計，不是由文獻導出；長期記憶的文獻背景見本章第四節，但文獻並沒有證明它對本研究的預測有幫助。

第七節　偷看未來的問題與金融評估

一、資料時間邊界與模型的訓練記憶

Glasserman and Lin (2023) 指出，用 GPT 產生情緒訊號去預測報酬時，模型可能因為本來就知道這些公司的後續發展，而產生「偷看未來」的偏誤（前視偏差），並嘗試用匿名化來緩和。Kong et al. (2026) 整理出金融語言模型研究中常見的五種偏誤（前視、存活、敘事、目標與成本偏誤），並指出多數研究沒有明確處理這些問題。因此，本研究在資料端嚴格排除分析日之後的資訊，並用前導階段做的「資料回想」與「匿名辨識」兩項探針，作為初步的風險檢查（見第五章第二節第二項），回測時也扣除交易成本。不過這些探針並不是新版主樣本完整的汙染檢驗。

第八節　文獻小結與研究缺口

一、從機制、模型到任務分工的連續問題

本研究承接辯論、自我一致性、角色交換、金融文字處理與前視偏差等文獻，先從最基本的問題開始：資料固定時，自我反駁是否有額外價值？再往下檢驗，指定的模型組合與領域分工，是否會改變決策。RQ2 與 RQ3 是 RQ1

之外並列的延伸問題；現有文獻還不足以證明「模型太相似」或「資訊太多」會限制機制效果，因此兩者只是候選假說，不是RQ1結果已證實的原因。對RQ2、RQ3而言，現有文獻只提供架構與評估方式的背景，並沒有針對金融決策的受控比較，這正是它們被列為設計階段問題的原因。三個研究問題提供的是可被查核的比較，而不預設哪種架構一定比較好。此外，文獻中的問答正確率、事實查核與投資報酬預測，評估的目標並不相同，不能直接畫上等號。

第三章　研究方法

第一節　研究架構

一、共用資料層與三個實驗分支

系統原有的協調者（Coordinator）、資料快照（Data Snapshot）與四類研究代理人（Research Agents）都保留。共用資料層會產生一份「不帶投資方向」的鎖定研究資料與證據登錄。RQ1、RQ2 讀的是同一份中立報告（Neutral Report）；RQ3 的通才組也讀這份中立報告，而領域組則使用同一份研究輸出依領域切開的部分，不另外抓新資料，也不用別的摘要模型重做輸入。整體概念架構如圖 3-1。為了讓圖中的用語在使用前先有定義：候選決策，是裁決者決定投資方向之後、守門員處理之前的決策；守門員（Gatekeeper）在候選決策之後檢查證據與風險，必要時降為持有（詳見下一小節）；A、B、C、D 是四組決策機制，見「四組決策機制」；M1、M2 是基礎模型，見 RQ2 設計。

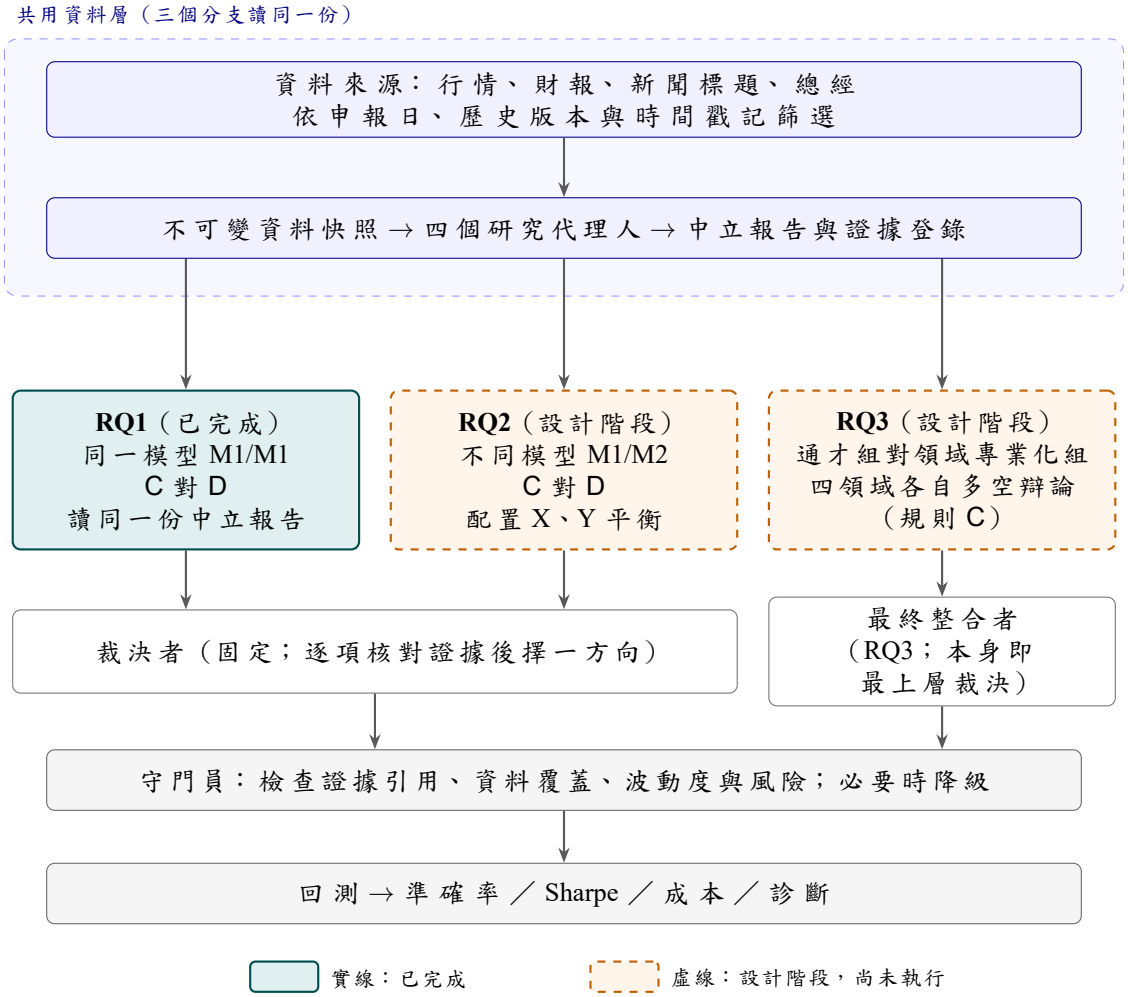


圖 3-1 研究概念架構。三個分支共用同樣的資料、候選決策與評估方式；實線為已完成，虛線為設計階段（尚未執行）；RQ3 為平行的架構延伸，不檢驗立場交換。

二、裁決者與守門員

裁決者（Judge）綜合辯論內容、核對證據，並決定投資方向。最終整合者（Final Aggregator）只用在 RQ3，負責整合四個領域的看法；它本身就是最上層的裁決者，因此不再另外設一位決策裁決者。守門員（Gatekeeper）在投資方向決定之後才出場，檢查證據引用、資料覆蓋、波動度、風險門檻與基準率歷史，必要時把決策降級；它不負責整合四個領域的投資觀點。

第二節　資料收集

一、四類資料與時間控制

樣本是九檔美國大型股（AAPL、NVDA、GOOGL、MSFT、AMZN、JPM、MCD、INTC、GE），分析日為 2021 至 2025 年共 20 個季末。每個案例只用分析日以前就已公開的資料（表 3-1）：財報依「申報日」而不是「會計期末」篩選；總經資料使用當時實際已發布的歷史版本；資料快照以內容的「雜湊值」（可想成這份資料的指紋碼，內容一改就會不同）來辨識，四組決策機制讀的是同一份快照。

表 3-1 資料來源與處理方式

類別	來源	內容與處理
技術面	調整後日行情	近 20 日報酬、均線相對位置、年化波動度；只用分析日以前的價格
基本面	SEC 財報	營收、淨利、營業現金流，並與去年同期比較；依申報日篩選
情緒面	金融新聞標題（FNSPID、Alpha Vantage）	分析日前 90 天的全部標題（既有資料共 83,093 則），以 FinBERT 逐則評分後彙整
總經面	FRED ／ ALFRED	失業率、利率、物價等，只採分析日當時已發布的數值

九檔股票主要依「資料取不取得到」挑選，不是從 2021 年的成分股中隨機抽出。實驗規則記錄了兩項調整：新聞來源沒有涵蓋的 ASTS 被排除；早期新聞有缺口的 LLY 被換成 INTC。所以樣本是有目的地挑選的，也有存活偏誤的風險（只看到活下來的公司）(Kong et al., 2026)。主要比較保留全部 180 案；先前排除 37 案的分析，只當成新聞來源與覆蓋範圍的診斷，不用它的結果去訂一個統一的新聞數量門檻。

二、資料品質與版本風險

為了讓快照只反映分析日當時能知道的資訊，本研究做了三件事。第一，財報依申報日期而不是會計期末篩選，並且用相同會計科目、相同期間長度與去年同期比較，避免把不同期間混在一起。第二，年增率的分母用前

期的絕對值，這樣當基期是負數、狀況又變差時，年增率會是負的，不會因為正負號而誤導。第三，快照以雜湊值識別，同一個模型、同一個案例的四組決策機制，讀的都是同一份快照與中立報告。行情使用 yfinance 的 auto_adjust=True；調整係數反映的是「下載當下」的拆股與股利處理，並不是各分析日當時保存的版本，因此仍有事後被修訂的風險。

在時間上，新聞依發布時間與時區篩選，財報以申報日判斷「何時才看得到」，總經資料用分析日當時已發布的歷史版本，價格輸入只使用截止時間以前的資料。每個案例都會記錄資料版本、快照雜湊值、證據編號、程式版本、模型版本與稽核紀錄。不過，「各組共用同一份快照」並不能單獨證明資料內容是對的，還必須檢查資料的可用時間與來源。模型版本、新聞來源與行情調整版本，都會影響能不能精確重現結果，所以要和快照、執行紀錄一起保存。

第三節　實驗設計

一、共同的實驗設定

各條件使用相同的案例、資料快照、結果（outcome）與回測。研究代理人用的模型與輸出、中立報告與證據登錄都固定，避免更換辯論者時，同時改變了輸入資訊。C、D 兩組的三輪辯論與裁決者呼叫次數對齊；模型設定、提示詞指紋碼、實際的隨機種子、token 用量與重試次數，都記錄在稽核紀錄中。

「記憶」只包含分析日以前已經「到期」（60 日結果已經揭曉）的同一檔股票案例，禁止讀取該案例本身的未來報酬，也禁止讀取其他條件的測試結果。RQ1 目前的設定是：C、D 的裁決者可以讀這類已到期記憶，A、B 不行（見第四章第二節第三項）。記憶、反思與角色分工屬於代理人架構的組成 (Shinn et al., 2023; Park et al., 2023; Yu et al., 2024)；A、B 代表不使用代理人架構的一般用法，所以沒有記憶（設計理由見表 3-4）。依研究服務程式讀取記憶的規則，系統只取「相同實驗規則雜湊值、同一檔股票、同一組別、相同期間與成本模型」的過去案例，且該案例的到期日與分析日都必須早於目前案例的分析日，只取經守門員處理後的決策、排除降級案例，每組最多取最近 20 筆。也就是說，C 與 D 各自只讀自己這一組過去的決策與對錯，彼此隔離，不會讀到另一組的決策；D 的記憶內容是 D 自己過去決策的結果，和

C 不同，這也是「整套流程」差異的一部分。

須注意的是，以上記憶的時間與條件邊界已於 2026 年 10 月 15 日由封存快照核對，但其語意影響與原執行環境的完整重現仍有限制（見第五章第四節第四項）；在核對完成前，本文不把 C、D 的差異解讀為單一機制的因果效果。RQ2、RQ3 若執行，必須讓各條件的記憶彼此隔離：每個條件只讀自己已到期的案例，不共享決策，並逐案記錄當時可讀內容與到期規則。由於後面案例的輸入會受到前面決策的影響，比較的是「整套流程動態運作的效果」，而不是各次獨立判斷的差異。模型服務的版本與內容被截斷的情形，也必須記錄。

二、四組決策機制

A 組（單次判斷）與 B 組（七次獨立投票）只當作補充對照，主要比較是 C 與 D。B 組是簡化版的自我一致性（self-consistency）多數決 (Wang et al., 2023)：同樣的提示詞獨立取樣，再對買進、持有、賣出三類取多數決，沒有原方法中對推理路徑的邊際化。若最高票有兩類以上同票（例如 3–3–1），則在這些同票樣本中取信心度最高的一份，並沿用該份的預期報酬與理由；信心度也相同時，取樣本順序在前者。RQ1 的 180 案中只有 1 案出現同票（持有 3、買進 3、賣出 1），依信心度決定為買進，沒有出現信心度也同分的情形。取七次是為了與 C、D 的呼叫次數對齊，不是原論文的取樣數；等呼叫預算的對照也是比較辯論效果時所需要的 (Smit et al., 2023; Zhang et al., 2025)。A、B 代表不使用代理人架構的一般語言模型用法，只有 C、D 有長期記憶，所以 A、B 對 C、D 的比較同時混合「有無辯論」與「有無記憶」，只作參考。四組的流程如表 3-2。B、C、D 三組的決策呼叫次數對齊（各 7 次），A 則是單次判斷的基準。這裡的 7 次是「預定」的次數：D 組若引用自己原文的驗證沒通過，可能另外觸發重試；呼叫次數相同，不代表實際的重試次數、token 用量或運算量相同，而且辯論組因為要讀歷史論述，輸入也比較長。每次決策都輸出買進（做多）、持有（不進場）或賣出（放空），並附上 60 個交易日的預期報酬、信心度、理由與引用的證據。本文用 A、B、C、D 代表決策機制；RQ2 的基礎模型則另外用 M1、M2 表示，以免搞混。

表 3-2 四組決策機制

組別	名稱	呼叫次數	流程
A	單次判斷	1	讀完報告後直接決策
B	獨立投票	7	同樣的提示詞獨立取樣七次，以多數決決定
C	固定立場辯論	7	看多與看空辯論三輪：第一輪各自提出論證；第二、三輪可以看到已完成輪次中雙方的論述；最後由裁決者決策
D	立場交換辯論	7	第二輪雙方換邊，只能看到自己的第一輪並且必須反駁它；第三輪換回原立場；最後由裁決者決策

三、固定立場辯論 C

C 組的看多與看空在三輪中都維持原本的立場，每輪各呼叫一次，依規定可以看到的內容進行批評與整合，最後交給固定的裁決者；預定決策呼叫次數共七次。

四、立場交換辯論 D

比較的對象。 本專題估計的是「整套 D 流程」相對於「整套 C 流程」的效果差，其中包含立場交換、交換輪看不到對手、強制引用自己原文，以及相對應的驗證與重試。因為這些因素同時改變，所以不能把結果歸因於單獨的「立場交換」。

立場交換辯論的流程。 表 3-3 是 D 組的三輪流程。第二輪刻意不讓角色看到對手的論述：如果同時看得到對手，模型容易變成在回應對手，而不是檢討自己的主張。辯論組的裁決者必須逐項核對雙方引用的證據，並綜合雙方論點，在買進與賣出之間選一個。

表 3-3 立場交換辯論的三輪流程

輪次	內容	目的
第 1 輪	看多與看空代理人各自提出論點並引用證據	建立正反兩方的初始立場
第 2 輪	雙方換邊，只能看到自己第一輪的論述，必須引用並反駁自己原本的主張	逼代理人找出自己論點的弱點
第 3 輪	雙方換回原立場，整合前兩輪的論點與反駁	產生整合後的論點，並說明不確定的地方
裁決	讀取完整辯論與報告，逐項核對證據後擇一方向	避免只看誰講得比較大聲

在三輪之中，模型本身固定不變：只有「立場」在第二輪反過來、第三輪再換回。「必須引用自己第一輪原文」的驗證規則與重試，是處理流程的一部分，正式實驗前會保存驗證程式的指紋碼。目前的原文核對，是要求至少 70% 的字詞連續相同；這只能檢查引用有沒有來源，不能證明反駁的內容真的有道理。

五、研究設計選擇與理由

下表使用的A、B、C、D四組與各角色，已在前面的小節定義。

表 3-4 主要設計選擇及其用途

設計	設定	理由
辯論者	看多與看空	用兩個相反的方向，建立最簡單的多空論證結構（類似 TradingAgents 的多空研究員分工 (Xiao et al., 2024)，以及多代理人辯論的做法 (Du et al., 2023)）。
辯論輪次	三輪	D 組：第一輪提出論證、第二輪自我反駁、第三輪整合修正。C 組：三輪都維持原立場，並依看得到的內容批評與整合。輪數只是操作上的選擇，不宣稱是最佳的。
交換時點	第二輪	先有可以引用的原始主張，再要求從反方向檢查（辯論中途交換角色的做法見 (Liu et al., 2025)）。
交換輪能看到的資訊	只有自己的第一輪	把反駁的對象限定為自己的主張，避免變成模仿對手。這是本研究自訂的設計，沒有直接的文獻依據。
第三輪	回到原立場	把反面證據與不確定性整合進來，觀察修正後的論點。
裁決與驗證	裁決者之後接守門員	把「決定方向」、「證據是否有效」與「風險控制」分成三件事；獨立裁決者的做法參考 (Zheng et al., 2023)，守門員則是本研究自訂的驗證設計。
主要比較	C／D 預定呼叫次數相同	控制其中一項推論資源的差異。等呼叫預算的比較才公平，這也是辯論研究與多次取樣投票比較時的要求 (Smit et al., 2023; Zhang et al., 2025)；辯論的成本可能是單次判斷的許多倍 (Chowdhury et al., 2026)。實際用掉的 token 與重試成本另外報告。
分析頻率	每季一次	配合財報按季更新的節奏，並沿用既有資料流程與 20 個決策時間點。
主要期間	60 個交易日	當作季度研究的實際持有期間；30 與 90 日用來檢查結果對期間敏不敏感，不宣稱 60 日在理論上最好。
長期記憶	只有 C、D 的裁決者可讀同一檔股票、同一組別、已到期的過去案例；A、B 不讀記憶	A（單次判斷）與 B（多次取樣多數決）代表不使用代理人架構的一般語言模型用法；記憶、反思與角色分工是代理人架構的組成 (Shinn et al., 2023; Park et al., 2023; Yu et al., 2024)，因此只放在 C、D。主要比較 C 對 D 兩者都有記憶，條件對等；但記憶讓 C、D 的差異也包含「各自的歷史」，仍屬整套流程差異。A、B 對 C、D 的補充比較同時混合「有無辯論」與「有無記憶」，只作參考，並列入研究限制；未來可做 C、D 移除記憶的消融。
資訊領域	技術、基本、情緒、總經	沿用既有四類證據，區分「整理資料」與「做決策」兩層的專業化。

各組共通的輸出格式與一般性的證據驗證設定，屬於實作上的參數，與C／D、模型組合、任務架構等「研究要比較的因素」分開記錄。D組專屬的「自我引用驗證」，以及驗證不過時觸發的重試，則是整套D流程的一部分，和立場交換、資訊隔離一起構成要比較的對象。

六、RQ1的設計

在相同的案例資料與相同的預定決策呼叫次數下，自我反駁式立場交換辯論（D）的60日方向準確率與年化Sharpe，是否高於固定立場辯論（C）?

RQ1維持「同一個模型當辯論者」、同樣的資料與七次預定呼叫，估計整套D相對於整套C的方向準確率差與Sharpe差；A、B只作補充對照。股票代號與公司名稱在輸入模型時都做了匿名化(Glasserman and Lin, 2023; Kong et al., 2026)，並且鎖定版本、事先寫好分析計畫，讓執行規則前後一致。匿名化並不能排除模型從數字、日期與產品線索猜出公司。RQ1屬於已見樣本的回溯比較：同一批樣本曾用於試跑與規則調整，因此不是事前確認性檢驗。

七、RQ2的模型組合設計

RQ2只改變「多空辯論者用哪個模型」，其餘全部固定：案例、資料快照、中立報告、研究代理人、三輪規則、立場交換規則、裁決者、守門員、結果與回測。我們用M1、M2代表兩個基礎模型：M1預定沿用既有主分析的qwen3:32b (Yang et al., 2025)；M2已指定為gemma3:27b (Gemma Team, 2025)，其確切權重、版本與推理設定（包括裁決者與研究摘要用的模型），會在執行前寫入實驗規則並鎖定。同一模型的條件是M1/M1；不同模型的條件有兩種平衡配置：配置X（看多M1、看空M2）與配置Y（看多M2、看空M1）。兩種配置都要有C與D，避免M1永遠擔任看多方。M2/M2的同模型條件是必要組別（不再視資源而定），用來分開「模型本身的能力」與「組合的效果」。每個條件至少以三個不同的隨機種子重複執行（確切數量於登記前鎖定），並報告種子之間的變異，避免把單次生成的雜訊當成效果。模型名稱標籤與論點的呈現順序也要控制，以降低文風與裁決偏好帶來的影響（裁決者的自我偏好與文風偏誤見(Zheng et al., 2023)）。

表 3-5 不同模型的 D 組中，模型身分與立場的對應（模型不會隨立場一起交換）

輪次	配置 X	配置 Y
第 1 輪	M1 看多；M2 看空	M2 看多；M1 看空
第 2 輪	M1 看空；M2 看多	M2 看空；M1 看多
第 3 輪	M1 看多；M2 看空	M2 看多；M1 看空

主要比較量。 RQ2 要問的是：「整套立場交換流程相對於固定立場流程的差異（D−C），會不會隨著模型組合而改變？」所以主要比較量直接定義為「差中之差」：

$$\Delta_{\text{acc}} = (\text{Acc}_{D,\text{het}} - \text{Acc}_{C,\text{het}}) - (\text{Acc}_{D,\text{hom}} - \text{Acc}_{C,\text{hom}}),$$

（het 代表不同模型的條件，hom 代表同一模型的條件。）Sharpe 的對應比較量為 $\Delta_{\text{SR}} = (\text{SR}_{D,\text{het}} - \text{SR}_{C,\text{het}}) - (\text{SR}_{D,\text{hom}} - \text{SR}_{C,\text{hom}})$。兩者衡量的都是 D−C 差異是否隨模型組合而變。同模型的對照有 M1/M1 與 M2/M2 兩個，上式分別以兩者當作 hom，各得一組結果；若兩組結果方向不一致，結論只限於各自的模型組合。M1/M1 與 M1/M2 的比較，同時也改變了模型的能力組成，所以結果只適用於這組指定的模型，不能解讀成「異質模型一般都有好處」。

兩種配置如何合併（預定做法，執行前鎖定）。 在不同模型的條件下，每個案例的方向正確性，取配置 X 與 Y 的平均（0、0.5 或 1）；日報酬序列則取兩種配置組合日報酬的等權平均，再用與 RQ1 相同的規則算 Sharpe。兩種配置共用同樣的案例與結果，不能當成兩倍的獨立樣本；也不能把兩個 Sharpe 直接平均，或把兩條序列接在一起。統計推論以「分析日」為單位，把同一天的案例綁在一起做重抽樣（區塊 bootstrap），估計上述兩個比較量的信賴區間與 p 值。目前分析原型把 M1/M1 與 M2/M2 兩個基準各自的準確率、Sharpe 共四個端點放在同一個 Holm 校正 family，採雙尾檢定；這是正式登記前須確認並鎖定的提案，不從兩個基準中挑選較好的結果。由於平均後的正確性不再是「對／錯」二元結果，所以不使用一般的 McNemar 檢定。

八、RQ3 的領域分工設計

通才（Generalist）架構是由共同的看多／看空代理人，讀四類資訊整合後的研究報告。領域專業化架構則把同一份研究輸出依領域切開，分給技術

面、基本面、情緒面與總經面各自的多空辯論；每個領域做出一份「領域看法」（Domain View），再由最終整合者（Final Aggregator）整合成一個候選決策，之後接相同的守門員與回測。RQ3 比較的是「整套領域化架構」相對於整套通才架構；其中同時包含決策層的任務拆分、資訊切分與額外的呼叫次數，所以結論只稱為架構效果，不稱為單純的分工效果。預定的流程如表 3-6。為固定辯論規則、避免再混入立場交換，兩種架構都採用 RQ1 的固定立場規則 C；呼叫數與資訊切分仍同時改變，因此 RQ3 比較的是架構套組。

表 3-6 RQ3 預定流程（設計階段，尚未執行）

項目	通才組	領域專業化組
辯論者與證據	共同的看多／看空，讀整合報告	每個領域各有看多／看空，只讀該領域的證據
辯論規則	C：三輪固定立場	每個領域都用 C：三輪固定立場
領域內裁決	無	每個領域有一位裁決者，輸出標準格式的領域看法（方向、支持證據、反面證據、不確定性、資訊缺口；資訊不足時可以棄權）
上層整合	裁決者直接裁決	最終整合者讀四份領域看法，用「裁決」（不是投票）決定單一候選方向
後處理	相同的守門員與回測	相同的守門員與回測
預定決策呼叫次數（示例）	7	$4 \times 7 + 1 = 29$

表中的呼叫次數只是這個設計下的預定示例，不是實際測到的用量。真正做研究時，研究、辯論、整合與重試的呼叫次數、輸入／輸出 token、推理時間與整體延遲都要記錄，用來呈現「績效」與「成本」之間的取捨。四份領域看法都針對同一個 60 交易日的方向；所謂 4:0、3:1、2:2 的意見分歧，只適用於四個都有效的二元方向，資訊不足或棄權的另外列出。這裡的「領域專業化」，指的是角色與證據範圍上的分工，並不是已經證明模型具有金融專業能力，也不是對模型做金融微調。

RQ3 主要比較的是整套架構的績效與成本，結論只限於「架構效果」：通才組與領域專業化組同時改變了分工、呼叫次數與資訊切分，績效差距

不能說成「純粹是分工造成」。為了分辨架構效果的來源，另外設兩個必要的對照：（一）運算資源對齊對照，讓通才組使用與領域化架構相同的總預定呼叫次數（約 29 次，例如多次取樣後投票）；（二）資訊切分消融，把資訊同樣切成四個領域，但各領域不辯論，改由單一裁決者直接讀四份領域證據。目前原型將運算對照設為 28 次彼此不可見的獨立提案與 1 次整合裁決；切分對照為單一裁決者直接讀取四份領域證據、不進行辯論。兩者均使用相同的守門員與回測，並有逐步續跑的合成測試；這些設定仍須在真實模型資格檢驗後寫入正式登記。

主要指標是方向準確率與年化 Sharpe，怎樣算勝出、多個比較如何校正，都在執行前事先寫定（表 3-7）。

此外，目前另有隔離 pilot ／研究輸入庫執行入口，以及從唯讀凍結快照建立完整四組共同案例面板的離線分析入口。RQ3 分析原型對領域組分別減去 C、29 次通才對照與資訊切分對照，產生三個比較的準確率差與 Sharpe 差，提供六端點共同 Holm 校正的保守提案；若正式計畫改用主要／次要 family，必須在執行前另行鎖定並驗證。分析程式已用合成的完整 180 案快照測試，尚無真實 RQ3 結果，也不能以此取代模型資格。RQ2 的研究輸入庫另用不在正式種子清單中的 seed（例如 904），在任何決策前鎖定並暫停；正式 905 ／ 906 ／ 907 共用該逐案報告，避免來源工作佔用正式案例。

九、評估方式

回測與主要比較。 在分析日後第一個交易日的開盤價進場，持有 60 個交易日後以開盤價出場，並扣除用 Corwin–Schultz 方法估計的買賣價差成本 (Corwin and Schultz, 2012)；這只是價差成本的近似，不含衝擊成本與手續費。主要比較是 D 對 C，用兩個共同的主要指標：方向準確率（用配對的 McNemar 檢定 (McNemar, 1947)，其獨立性假設見「統計分析」；這是檢查兩種方法對同一批案例的對錯有沒有系統性差異的檢定），以及年化 Sharpe 比率 (Sharpe, 1994) 的差（用 Ledoit–Wolf 檢定 (Jobson and Korkie, 1981; Ledoit and Wolf, 2008)）；兩個指標一起以 Holm 法 (Holm, 1979) 校正（保守起見仍採用），採雙尾檢定。只有當兩個指標的差異都是正的，而且各自校正後 $p < 0.05$，才判定 D 比較好。這是「兩個指標都要顯著為正」的交集規則，搭配雙尾檢定，只承認 D 的正向結果；在這種規則下，Holm 校正偏保守。保留這套規則，是因為它在看到結果之前就已鎖定，不因結果而更動。RQ1 的問句寫「是否高

於」，但檢定採雙尾，是為了同時報告負向的差異。另外，30 與 90 日、不計成本、排除先前新聞來源／覆蓋診斷的子集（37 案；名單與選取規則須在定稿前核對並附上）、以及依日期分組的信賴區間，都屬於敏感性分析（換個設定看結論會不會變）。

為了判斷辯論流程是否勝過最簡單的做法，結果章另外報告兩個參照。「買進持有」是對同一批案例、同一配置一律持有部位，作為 Sharpe 的參照；「一律看多」是每個案例都預測方向向上，作為方向準確率的參照。這兩個比較是看到結果後才加入的探索性分析，未經事前登記，也未對多重比較校正。

報酬與 Sharpe 的算法。 日報酬先依每個案例「進場開盤價、每日收盤價、出場開盤價」算出部位的價值變化，並扣掉進出場的價差成本；同一天的各個案例用固定權重 1/180，沒有持有或不在交易期間的報酬記為零。年化 Sharpe 為 $\sqrt{252}\bar{r}/s(r)$，也就是「平均日報酬除以日報酬的標準差，再乘上一年的交易日數開根號」。其中，案例數 $n_{\text{case}} = 180$，分析日的分組數為 20，T 是對齊後日資料的交易日筆數（2026 年 10 月 15 日由唯讀快照重算：2021-04-01 至 2026-03-31，$T = 1219$），這三個數字不能互相替換；標準差的分母用 $T - 1$，無風險利率明設為零。累積報酬為 $\prod_t(1 + r_t) - 1$，不是各案例 60 日報酬的平均；最大回撤（資產從最高點下跌的最大幅度）也由這條日序列計算，這種低曝險配置只適合用來比較各組，不適合當成實際績效。方向是否正確，是依未扣成本的開盤價漲跌判斷，和扣成本後淨報酬的正負不同。Ledoit–Wolf 檢定的重抽樣區塊長度為 20 日，每次重抽樣的長度為 $20\lfloor T/20 \rfloor$，共重抽 1,999 次，隨機種子 905；qwen 的基礎推理種子是 905、溫度 0.2（投票組 0.8），各次呼叫實際用的種子另外保存在稽核紀錄中。

次要指標。 次要指標包含累積報酬、最大回撤、決策分布、信心度、扣除交易成本後的報酬，以及意見分歧。RQ2 另外報告看多與看空雙方的分歧、不同模型決策的差異，以及各模型偏向看多或看空的傾向；RQ3 報告四個領域各自的立場、一致程度，以及跨領域衝突如何處理。要注意：意見分歧增加、引用更完整，或比較常看空，都不直接代表績效有進步；信心度是模型自己報的數字，不能自動當成校準過的機率。候選決策層與守門員之後的結果分開報告覆蓋率、有出手時的準確率與日報酬；無風險利率設為零與低曝險配置的限制，也要揭露。

機制指標（預先定義）。為了檢查「自我反駁」是否真的改變了推理，而不只是改變文字，定義三個機制指標：（一）反面證據引用率，即第二輪引用的證據中，原本支持對立立場者所占的比例；（二）裁決者引用證據的組成，即裁決者引用的證據中，支持買進與支持賣出各占的比例；（三）方向翻轉率，即第三輪預期報酬的方向與第一輪不同的比例。RQ2、RQ3 會在執行前把這些指標寫入登記；RQ1 的 180 案先前沒有登記這些指標，只能在原始輸出補齊後以探索性方式描述，不作為確認性結論。這些指標只有在同時伴隨績效改善時，才被解讀為機制的證據。

十、統計分析

RQ1 沿用配對的 McNemar 檢定、Ledoit–Wolf 檢定與區塊重抽樣、雙尾檢定、兩個指標共同的 Holm 校正，以及依日期分組的敏感性分析；只有當兩個指標的差異都是正的、而且校正後仍顯著，才算支持 D 比較好。180 個案例共用 20 個分析日、同一檔股票反覆出現，持有期間也有重疊，所以「各案例互相獨立」這個假設必須用分組／區塊的方法檢查；而且日期分組的數目有限，不能把敏感性分析當成已經充分校正的證明。由於 McNemar 檢定把 180 案視為互相獨立，本文在解讀 RQ1 時，把依日期分組的信賴區間與預定的檢定並列，作為考慮案例相依之後的判斷依據。兩個指標的區間都包含 0（準確率差 $[-7.2, +0.6]$ 個百分點、Sharpe 差 $[-0.47, +0.36]$），與預定檢定的結論一致，所以結論不隨檢定方式而改變。這是看到結果之後才提高日期分組推論的地位，並沒有更改預定的判準；RQ2、RQ3 則從一開始就以依日期分組的推論為主分析。結果沒有顯著，不等於兩者一樣好或「不比較差」，而「算作一樣好」的界線也不能看完結果才補訂。

RQ2 的主要檢定是第三章第三節第七項的差中之差 Δ_{acc} 與 Δ_{SR}，而不是分別檢定各條件下的 D−C。如果一組顯著、另一組不顯著，這件事本身並不能證明「效果隨模型組合而變」。兩種配置共用案例，平均後的正確性不再是二元結果，所以不能直接套用一般 McNemar；Sharpe 也要由配對的日序列計算，不能把兩個 Sharpe 平均，或把兩種配置接成兩倍的觀測數。

RQ3 在相同的「股票 — 日期」案例上，比較架構與成本；各領域的論點只是同一案例的中間輸出，不是四筆獨立的金融樣本。主要指標與探索性的診斷要分開呈現，統計推論也要處理共同日期、同一檔股票與重疊持有期造成的相依，避免只挑對自己有利的次要指標。

三個研究問題比較的東西不同，不能把 RQ1 的判準不加說明地套到 RQ2、RQ3，整理於表 3-7；其中 RQ2、RQ3 兩欄是預定的設計，執行前會鎖定。共同的回測規則（進出場、成本、權重、無風險利率）見上面的「評估方式」。

表 3-7 三個研究問題的比較設計

	RQ1	RQ2	RQ3
比較條件	D 對 C（同一模型 qwen3:32b）	同模型 M1/M1 與不同模型 M1/M2（平衡配置）下的 D 對 C	領域專業化對通才
主要比較量	方向準確率差；Sharpe 差	差中之差 Δ_{acc}、Δ_{SR}	方向準確率差；Sharpe 差；成本另外報告
分析單位	180 個案例（Sharpe 由日序列計算）	同左；不同模型的條件先合併 X、Y 兩配置	同左
統計方法	配對 McNemar；Ledoit–Wolf 檢定與區塊重抽樣	以日期為單位分組的區塊重抽樣	同 RQ2，細節執行前鎖定
判準	兩個指標都為正，且 Holm 校正後 $p < 0.05$	兩個基準各兩指標，共四端點 Holm 提案；雙尾	三比較共六端點 Holm 提案；主比較兩指標都須為正且校正顯著
成本	預定呼叫次數對齊；token 與重試另外報告	預定呼叫次數對齊	呼叫次數、token、延遲全部報告，不併入門檻
狀態	已完成（回溯比較）	設計階段	設計階段

第四節　工具及設備

一、既有工具與 GPU

表 3-8 工具及設備

項目	工具	用途
程式語言與框架	Python、FastAPI	後端服務與網頁介面
流程控制	LangGraph	管理研究、決策、風控與回測的狀態流程
模型呼叫	Ollama、LiteLLM	部署開源模型 qwen3:32b (Yang et al., 2025)，並提供統一的模型呼叫介面
資料來源	yfinance、SEC EDGAR、FRED／ALFRED、FNSPID、Alpha Vantage	行情、財報、總經與新聞
情緒分析	FinBERT	新聞標題的正負面評分
儲存與部署	SQLite、Docker	保存案例與實驗紀錄；容器化部署
運算資源	雲端 GPU 主機	執行模型推理

第四章　系統設計與實作

第一節　系統架構

一、研究問題與功能分支

前一章說明要比較什麼，本章說明由哪些模組實際執行，並標示哪些已用於 RQ1、哪些只是原型。既有系統由協調者（Coordinator）掌管任務、資料邊界與記憶權限；中立報告鎖定之後，才分流到各個決策機制。網頁、命令列與程式介面共用同一套流程，目的是讓執行與稽核的結果一致。對應到研究架構：模型路由器（Model Router）對應 RQ2 的模型組合；領域辯論模組（Domain Debate Module）與最終整合者（Final Aggregator）對應 RQ3 的領域推理與上層整合。各模組的實作狀態見表 4-1（截至 2026 年 10 月 15 日）；原型與合成測試不代表真實模型資格檢驗或正式實驗已完成。

第二節　功能模組

表 4-1 功能模組的實作狀態

模組	狀態	對應
協調者與資料快照	已實作	RQ1 使用
研究代理人	已實作	RQ1 使用
短期與長期記憶	已實作	C、D 的裁決者可讀
裁決者、守門員與回測	已實作	RQ1 使用
模型路由器	已實作原型	RQ2；已隔離條件記憶，真實模型資格待補
領域辯論模組	已實作原型	RQ3；必要對照已有合成驗證，真實資格待補
最終整合者	已實作原型	RQ3；輸入含引用證據與基準率

一、協調者與資料快照【已實作】

協調者負責固定案例、實驗規則、截止時間與模型設定；資料代理人負責建立不可更動的資料快照，快照的雜湊值與證據編號會連到執行紀錄。

二、研究代理人【已實作】

四個面向的研究代理人，各自在同一個時間邊界內摘要並引用證據，產生鎖定的中立報告與各領域的輸出；驗證失敗而改用來源原文摘錄的降級處理時，系統也會記錄。

三、短期記憶與長期記憶【已實作】

短期紀錄保存每次呼叫的提示詞指紋碼、隨機種子、用量、辯論內容與裁決；長期記憶只讀分析日以前已到期的同一檔股票案例。目前C、D的裁決者可以讀長期記憶，A、B不行，所以解讀補充比較時要把這個權限差異考慮進去。這樣設計，是因為記憶、反思與角色分工屬於代理人架構的組成(Shinn et al., 2023; Park et al., 2023; Yu et al., 2024)，而A、B代表不使用代理人架構的一般用法。此外，記憶必須「到期」才能被讀取，以避免過去的案例讀到未來的結果。

四、裁決者、守門員與回測【已實作】

裁決者逐項核對論點與證據後，輸出候選方向；守門員檢查引用、資料覆蓋、波動度與基準率歷史，必要時降級。回測用相同的開盤進出場、成本與日序列計算，不會把四個領域的看法當成四個部位。

五、模型路由器【已實作原型，尚無正式結果】

模型路由器目前實作的核心功能是：記錄每個代理人的身分、起始立場、每輪立場與模型編號／版本，並依M1/M2的平衡配置（配置X、Y）呼叫不同的模型；第二輪只改立場，引用的對象仍是同一個代理人的第一輪。系統禁止在背景默默換成別的模型（fallback），也要記錄API是否支援固定種子，以及服務商端是否有模型版本漂移。

六、領域辯論模組【已實作原型，尚無正式結果】

領域辯論模組目前實作的核心功能是：把同一份快照中各領域的證據，分給各領域的看多／看空，依指定的辯論規則執行，並保存各領域的辯論逐字稿與領域看法。證據的命名空間與可讀取的權限都要驗證。

七、最終整合者【已實作原型，尚無正式結果】

最終整合者目前實作的核心功能是：讀取格式統一的四份領域看法、其引用證據與基準率，評估其中的衝突、反面證據與資料缺口，輸出一個最終候選決策；它的提示詞、輸入順序與記憶都要版本化，之後仍然交給相同的守門員。

第三節　介面設計

一、研究台與流程追蹤

介面設計有兩個原則：「流程看得見」與「步驟有引導」。頁面上方的資料流向圖（圖 4-1）會即時顯示每個案例，從資料來源、研究代理人、中立報告、四組決策，到風控與回測的進度；點選任何一個節點，就能看到該步驟的輸入、模型輸出與紀錄。下方依「資料準備、建立實驗、代理人執行、統計結果」四個步驟分頁，使用者可以依序完成一次完整的實驗，同時查看執行終端與工作佇列。

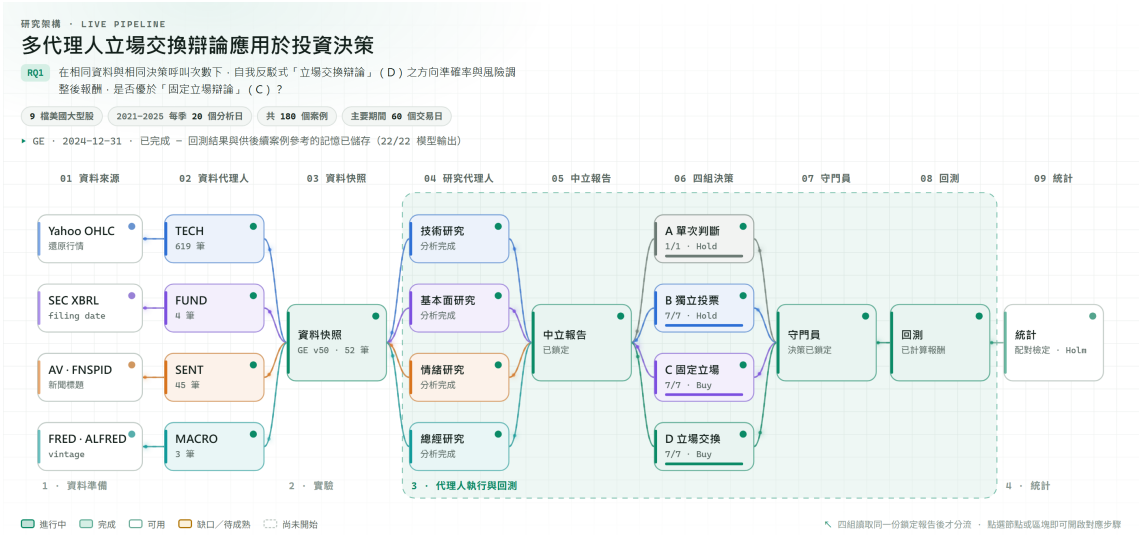


圖 4-1 網頁介面的資料流向圖（一個已完成的案例）。由左至右依序為資料來源、資料代理人、資料快照、研究代理人、中立報告、四組決策、守門員、回測與統計。

介面以執行狀態與來源追蹤來支援研究檢查；模型的指派、論證、裁決與資源使用的紀錄，都應該能對應到單一案例。

第四節　實作流程與驗證

一、開發流程

系統依「資料、研究、決策、回測、統計」的順序逐步開發。每完成一個模組，先用模擬資料與小樣本測試，再用少量真實案例試跑，最後才進行正式實驗。開發過程中主要的挑戰與對策如下：

- 時間邊界：財報與新聞要依「何時才看得到」篩選，避免分析日之後的資訊混進輸入；總經資料改用歷史版本，排除事後修正的影響。
- 模型輸出不穩定：模型常引用不存在的證據或輸出格式錯誤，所以用結構化輸出、證據短代稱與自動重試處理；模型也常自己改寫數字，所以改成要求用證據代稱來指稱事實。
- 結果可重現：系統設計上，在事前登記時鎖定程式與模型版本，每一步推理前後都核對模型權重，版本不符就拒絕執行。實際執行中仍有未完整保存的項目（FinBERT 版本、Gemini 呼叫設定、行情調整版本），見第五章第四節第四項。
- 長時間執行：網路中斷時自動暫停，恢復後接著跑，已完成的步驟不

重做，目的是讓 180 個案例在一致的條件下完成；180 案的原始輸出與版本對應，仍須在定稿前補齊。

二、稽核紀錄與版本核對

系統設計要求模型輸出在寫入前先驗證，並為每次呼叫建立稽核紀錄。下列項目是系統所支援的紀錄內容；現有 180 案是否全部具備完整紀錄，仍須以最終匯出清單逐案核對：

- 提示詞中的證據用短代稱（E1、E2、...）呈現，模型回答後再由程式對應回真正的識別碼。這樣可以避免模型抄錯很長的識別碼，也避免識別碼裡的申報編號洩漏公司身分。
- 引用的證據必須存在；如果引用不存在的證據或格式錯誤，系統會用明確的訊息要求重試，最多三次。
- 數字檢查：新版要求代理人用證據代稱指稱事實，而不是重述數字。敘述中如果還是出現沒有任何證據數值支持的數字（期間名稱、日期、來源值的四捨五入或截位不算），只記錄下來並依組別報告比例，不重試，也不修改文字。
- 凍結與身分核對：每一步推理前後，都核對模型權重的指紋碼；取不到時就暫停，之後可以接續執行；如果確認前後不同，該案例就永久作廢。程式原始碼的雜湊值也納入實驗規則的雜湊值，只要程式被改動就拒絕續跑。連線故障連續發生時，會暫停派發新案例，停滯太久時自動關閉 GPU 主機。
- 系統支援逐案匯出實驗規則設定、中立報告、證據登錄、執行軌跡、記憶、決策、逐案例回測、彙總指標與辯論逐字稿；本文不以此功能宣稱現有 180 案已全部完成可重現性核對。

第五節　實作上的挑戰

一、格式不同與輸入長度限制

不同模型的結構化輸出格式、分詞方式（tokenizer）與可讀的內容長度各不相同。轉接程式不能偷偷加入額外的金融資訊，也不能默默截掉某一方的

反面證據。所以需要統一輸出格式、保存模型的原始回應與截斷紀錄，限制輸入長度並記錄失敗的情況。

二、資源公平與領域輸出標準化

呼叫次數相同，不代表 token 用量、成本或延遲相同；四個領域平行執行時，實際花費的時間與累計的推理時間也會不一樣。各領域看法的長度、缺漏值、證據與反面證據欄位如何標準化，會影響上層的裁決，因此格式與提示詞必須先鎖定，不能看完績效再調整權重。

三、模型能力造成的混淆

有了模型路由，並不表示就能識別出「異質性」本身的效果。模型能力的組合、裁決者對某種文風的偏好 (Zheng et al., 2023)，以及不同模型的訓練記憶風險，都可能影響比較結果，所以要靠分開設定模型條件、控制輸入內容，並限定結果的適用範圍來解讀。

第五章　結果與討論

第一節　既有實驗規則下的機制比較

本節呈現 qwen3:32b、季度實驗規則 v3-1002.3 下的既有回溯比較，以及同一批案例的 Gemini 探索性分析。結果只適用於這個模型、這套流程與這批資料；本節不能當成「不同模型辯論」或「領域專業化架構」的績效證據。

一、qwen3:32b 的績效與配對檢定

180 個案例（季度實驗規則 v3-1002.3）全部完成，沒有排除任何案例。表 5-1 是四組的績效，表 5-2 是配對檢定。

表 5-1 四組績效（180 案，60 個交易日，已扣除交易成本）

組別	出手率	條件準確率	累積報酬	最大回撤	年化 Sharpe
A 單次判斷	78.3%	56.0%	1.85%	−1.81%	0.44
B 獨立投票	79.4%	55.9%	1.95%	−1.83%	0.46
C 固定立場辯論	100%	58.3%	2.51%	−1.47%	0.59
D 立場交換辯論	100%	55.0%	2.11%	−2.01%	0.54
買進持有（同案同期間）	–	–	5.60%	−1.59%	1.01

決策是守門員處理之前的候選決策。「出手率」是決定買進或賣出（不是持有）的案例比例；方向準確率只用有出手的案例計算。這裡把每個「股票 × 分析日」案例視為一個固定權重（1/180）的部位，只在該案例 60 日持有期間依決策做多或放空，其餘時間、以及決定持有的案例，都以零報酬的現金計算，所以不同案例的持有期間可能重疊。買進持有的基準採相同的配置：在每個案例的相同期間做多該股票，不是九檔股票全期間一直持有。

表 5-2 立場交換辯論（D）的配對檢定（60 個交易日）

比較	配對案例	方向不同	準確率差	McNemar p	Sharpe 差	Ledoit–Wolf p
D 對 C（主要）	180	16	−3.3	0.21	−0.05	0.80
D 對 B	143	9	+0.7	1.00	+0.08	0.79
D 對 A	141	8	+1.4	0.73	+0.10	0.72

準確率差的單位是百分點。主要比較經 Holm 校正後的 p 值為 0.42（準確率）與 0.80（Sharpe）。與 A、B 比較時，方向準確率與 McNemar 檢定只限兩組都有出手的配對案例；Sharpe 差與 Ledoit–Wolf 檢定，則使用各組在共同交易日上的完整組合日報酬序列，持有及非交易期間依既定規則記為零。配對案例數並不等於 Sharpe 檢定所用的日序列筆數。

在主要比較中，D 的方向準確率與 Sharpe 比率都略低於 C，但差異並不顯著。以日期分組計算，準確率差的 95% 信賴區間是 $[-7.2, +0.6]$ 個百分點，Sharpe 差的區間是 $[-0.47, +0.36]$。30 與 90 日、不計成本、守門員之後的決策、排除 37 個新聞來源／覆蓋診斷案例等敏感性分析，都沒有提供 D 優於 C 的顯著證據；但有些點估計的方向不同（例如 30 日的 Sharpe 差是 $+0.04$）。四組的 Sharpe 點估計都低於相同配置的買進持有參照（我們沒有對這個基準做優越性檢定）。

與研究問題對照。 研究問題是「自我反駁式立場交換，是否優於固定立場辯論」。依事前指定的判定標準，兩個主要指標都沒有顯著為正，所以不支持立場交換優於一般辯論。兩個辯論組的 Sharpe 雖然高於 A、B，但辯論組必須出手（不能選持有），在以上漲為主的期間，持有的時間較少；而且只有辯論組可讀長期記憶，因此這個差異不能歸因於辯論本身。

檢定力與「算作一樣好」的界線。 研究事前沒有訂下「兩組算作一樣好」或「不比較差」的界線，所以不能因為結果不顯著，就說兩組相同或不比較差。若固定觀察到的 16 個方向不一致的案例，並暫時假設各案例互相獨立，對單一的準確率指標做雙尾 $\alpha = 0.05$ 的精確檢定，要有 80% 的機會偵測到差異，預期差距約需 6.3 個百分點（這稱為「最小可偵測差距」）。這個數字沒有考慮日期之間的相依，也沒有考慮 Holm 校正與 Sharpe 的聯合門檻，更不是事前做的檢定力規劃。

決策分布。 180 案中，有 129 案（72%）四組的決策完全一樣，C 與 D 只有 16 案方向不同。以候選決策來看，四組都以買進為主（A 買進 108、持有 39、賣出 33 案；B 109、37、34 案；C 買進 145、賣出 35 案；D 買進 137、賣出 43 案），D 的賣出比 C 多。守門員只對 INTC 2024-09-30 這一案出手：因為波動度過高，把四組的賣出都降為持有。A 與 B 的買進、持有與賣出總數接近，只代表整體分布相似；逐案是否一致，還要等原始決策匯出後才能核對，所以我們不據此推論「七次投票」與「單次判斷」是等價的。

二、正反分歧的案例與可能的解釋

為了看 D 與 C 不同時實際發生了什麼，以下挑選兩個方向不同的案例作描述。這些案例是在結果揭曉之後才挑選的，只用來描述，不能用來判斷因果機制。這裡的判定標準適用於季度實驗規則 v3-1002.3；少數案例也不能

代表全部 16 個方向不同的案例。

案例一：INTC 2024-03-31（D 正確）。 研究報告顯示新聞情緒偏正面、近 20 日報酬為正，但營收、淨利與營業現金流都比去年同期大幅衰退。表 5-3 是兩組的辯論與裁決摘要（代理人原文是英文，這裡是摘要翻譯）。

表 5-3 案例一：INTC 2024-03-31 的辯論與裁決（60 日實際報酬 −30.5%）

組別／輪次	立場與預測	論點摘要
C 第 1–3 輪	第 1 輪：看多 +8%；看空 −12%	看多方三輪幾乎都在重複「情緒正面與短期動能支持看多」；看空方也一直重複財報衰退，雙方都沒有回應對方的核心證據（各輪預測值逐輪的變化，須由原始輸出核對）
C 裁決	買進，+5%	採納看多方的短期動能論點
D 第 1 輪	看多 +8%；看空 −10%	論點方向與 C 相同（預測值略有差異）
D 第 2 輪	原本看多的一方改看空，−7%	引用並反駁自己原本的主張：正面情緒與短期報酬「被營收、淨利與現金流的大幅衰退所抵銷」
D 裁決	賣出，−7%	基本面惡化的重要性高於短期情緒

這個案例中可以看到，交換輪特別強調了原本被輕描淡寫的基本面衰退，最後裁決也轉為賣出；60 日後股價下跌 30.5%，C 判斷錯誤，D 判斷正確。由於本段只分析主要的 C／D 比較，未經原始輸出逐案核對的 A／B 決策不在此列示。

案例二：AAPL 2023-03-31（D 錯誤）。 這個案例的技術面很強（近 20 日上漲 11.3%），但營收與淨利比去年下降。C 採納技術動能的判斷，決定買進；D 的交換輪則再次強調基本面衰退，裁決者因此判斷賣出。60 日後股價上漲 15.3%，D 錯了。

整體模式。 在 16 個方向不同的案例中，D 有 12 案判斷賣出；就這 16 案整體而言，D 對 5 案、C 對 11 案。兩個案例都看得到，交換輪會強調反面證據（多半是基本面衰退），而且 D 的最終決策比較常轉為看空，這與自我反駁的設計目的相符；但案例太少，不足以確定其中的因果。一個可能的解釋是：本研究的期間以上漲為主，「基本面疲弱但股價還是繼續漲」的情形比較多，所以比較常看空反而吃虧。此解釋的事後檢驗見第五章第二節第一項的「事後檢驗：D 偏空的解釋」。兩組的部分文字與決策確實不同，但這

並沒有顯示D比較好；也不能把差異全部歸因於交換立場。這個結論與「辯論效果常被高估」的文獻（在問答基準上）一致 (Smit et al., 2023; Zhang et al., 2025)。

三、與簡單基準的比較

這裡報告第三章評估方式定義的兩個參照：買進持有（表 5-1 末列）與「一律看多」(對全部 180 案都預測上漲)；後者是看到結果後才加入的探索性比較，未經事前登記，也未對多重比較校正。180 案中有 112 案在 60 日內上漲（62.2%）、68 案下跌（37.8%）；只有涵蓋全部案例的C、D可以直接與這個「事後才知道的方向」比較。

與「一律看多」的準確率比較。 在180案全部納入的條件下，C、D的準確率（58.3%、55.0%）點估計都低於「一律看多」的62.2%。「一律看多」與C、D只在C、D決定賣出的案例上不同，所以可由表5-4（由既有的決策總數與正確數重建完整分布，不是新的逐案驗證）做配對的精確 McNemar 檢定（事後、探索性，未對多重比較校正）：C賣出的35案中，C對而一律看多錯的有14案，反過來有21案（$p = 0.31$）；D賣出的43案中，分別是15案與28案（$p = 0.07$）。兩者都沒有達到0.05，但點估計都不利於辯論組。Sharpe相對買進持有的比較需要完整的日報酬序列，目前尚未檢定。因此，這批資料沒有顯示任何一種辯論流程勝過最簡單的基準；所以即使D與C有差異，也不能由此推論辯論流程本身具有可用的預測力。

賣出的精確率與召回率。 賣出的精確率（賣出的案例中，真的下跌的比例）分別是 40.0%（14/35）與 34.9%（15/43），和全樣本的下跌率 37.8% 相比，一個較高、一個較低；下跌的召回率（所有下跌案例中，被猜到要賣出的比例）分別是20.6%與22.1%。所以，只能說這兩組對下跌的召回偏低，不能概括說它們完全沒有辨識力。

表 5-4 qwen3:32b 的方向混淆分布（60 日，候選決策）

組別	預測方向	實際上漲	實際下跌	合計
C	買進	91	54	145
	賣出	21	14	35
D	買進	84	53	137
	賣出	28	15	43

每組總數為 180；正確數 C=105、D=99。這是由既有彙總數用代數重建的，不當作額外的逐案驗證。A／B 的持有分布與 Gemini 的完整分布，也不從四捨五入後的準確率反推。

第二節　探索性的跨模型分析與前導診斷

一、Gemini 同一模型的比較

5.1 的結果顯示 D 沒有優於 C。為了看這個結果是否只屬於 qwen3:32b (Yang et al., 2025)，以下用同一批案例換用 Gemini 3 Flash 做探索性比較。把整套系統改用 Gemini，仍然是單一模型的設定；RQ2 預定的第二個模型是 gemma3:27b (Gemma Team, 2025)，目的是在同一場辯論中混用兩個模型，與這裡檢視單一模型的用途不同。以下呈現同一批案例的探索性模型替換比較，以及解讀時的界線。

以下分析都是在主要結果揭曉之後才做的，沒有事先登記。依照 Wagenmakers et al. (2012) 與 Nosek et al. (2018) 的區分，這屬於探索性分析，只能用來產生後續研究的假說，不能當作確認性的證據。

跨模型比較。 我們用 Gemini 3 Flash，依照相同的案例集合、流程與匿名化設定，把四組重新跑一遍（表 5-5）。結果與 qwen3:32b 一致：D 的準確率仍略低於 C；C、D 方向不同的案例只有 9 案（D 單獨正確 3 案、C 單獨正確 6 案，McNemar $p = 0.51$）。這是在相同標的、日期與來源資訊上換模型的比較，不是用獨立資料重做一次。現有匯出的紀錄，不足以證明兩個模型的完整呼叫設定與逐案的研究報告完全一致，所以不能說兩個模型一字不差地讀到同一份報告，也不能把換模型的結果當成單純的「能力改變」。兩個模型的決策高度相似，C、D 分別有 165 與 162 案的方向相同。

表 5-5 跨模型比較：方向準確率（60 日、候選決策、有出手的案例）

組別	qwen3:32b	Gemini 3 Flash
A 單次判斷	56.0%	57.6%
B 獨立投票	55.9%	56.7%
C 固定立場辯論	58.3%	57.8%
D 立場交換辯論	55.0%	56.1%
一律看多（180 案）	62.2%	

兩個模型都報告 180 案。qwen 的 A、B 有出手的案例分別是 141、143 案（覆蓋率 78.3%、79.4%），C、D 是 180 案。現有的 Gemini 彙總資料沒有提供可以核對的 A／B 出手數與覆蓋率；C、D 依強制下注規則為 180 案。A、B 的條件準確率只涵蓋有出手的子集，不能直接與全樣本的 62.2% 比較；「一律看多」只能與 C、D 比較（見第五章第一節第三項）。

與「一律看多」的比較。 兩個模型的 C、D 準確率，點估計都低於「一律看多」的 62.2%；qwen 的細部分析見第五章第一節第三項。

事後檢驗：D 偏空的解釋。 本研究原本推測：D 比較常看空，所以在多頭時期吃虧，在空頭時期應該會比較好。我們把 20 個分析日，依九檔股票的平均 60 日報酬分成 6 個空頭季與 14 個多頭季，結果 D 在空頭季的準確率也沒有高於 C（qwen 是 24.1% 對 25.9%；Flash 是 25.9% 對 27.8%），兩個模型都只差一個案例，而且季別是事後才分類的。所以這份資料沒有支持上述推測，但也不能說已經推翻它。

兩個模型差異方向的描述。 兩個模型的 D−C 準確率差都是負的，方向一致（這只是描述）；我們沒有檢定「模型與機制之間的交互作用」、「兩者是否等效」，也沒有做跨模型 Sharpe 的聯合判準。由於用的是同一批樣本、分析屬於探索性，而且模型紀錄不夠完整，所以不能說已經確認了跨模型的穩健性。

後續假說。 在兩個模型的既有準確率結果中，我們都沒有看到 D 帶來改善。輸入資訊本身的預測力不足，是可能的解釋之一，但市場雜訊與效率、提示詞設計、模型限制、樣本數與生成的隨機變動，也都可能造成這個結果；本文沒有用實驗把這些原因分開。後續可以用新的期間或新的標的，先登記好擴充資訊與消融（逐項拿掉看影響）的方案，再檢驗跨標的的訊號是否真的有額外價值 (Nosek et al., 2018)；不能在產生假說的同一批資料上，把探索結果改稱是確認性的證據。

二、記憶與匿名辨識探針

這是第二章預告的前導探針，用來粗略檢查模型是否記得這段期間的股價走勢。專案已保存 2026 年 9 月 28 日 qwen3:32b 的前導探針。其中「無資料回想」測試用了 63 題、60 日期間、溫度 0、種子 905：2022、2023、2024 年各 9 題，方向正確率分別是 33.3%、33.3%、55.6%，2025 年 36 題為 72.2%，都沒有高於各組的「多數方向基準」(66.7%、66.7%、55.6%、72.2%)。這只能說，用這種問法沒有看到「超出基準的回想表現」，並不能證明模型沒有記憶。

另外，我們拿 2023-06-30 與 2024-06-30 各九檔股票的匿名證據前 6,000 字元，詢問「這是哪家公司」，qwen 辨識出 6/18（33.3%）；產品名稱與財報規模仍然提供了線索。這是開放式的回答，不是九選一的測試，所以不直接用 1/9 當作統計上的「純猜」基準。這兩項探針使用的是前導階段的實驗規則 39f71a9c，沒有完整保留可以比對的模型權重與新版研究報告的身分，所以不能當作 v3-1002.3 全部 180 案的辨識率。專案另有 Gemini 2.5 Flash 等其他模型的探針，也不能取代對本批 Gemini 3 Flash 的汙染檢驗。

第三節　討論

5.1 顯示 D 沒有優於 C，且 C、D 的準確率與 Sharpe 點估計都沒有超過「一律看多」與買進持有。這使「改變辯論條件就能改善結果」的期待變得保守：若輸入資訊本身缺乏預測力，RQ2、RQ3 也可能同樣看不到改善；「一律看多」的比較又是事後加入的探索性分析，這個先驗只能當作謹慎的提醒，不是定論。

即使如此，RQ2、RQ3 仍值得做，原因在於本研究的目的：比較不同辯論設計之間的差異，檢驗立場交換、模型異質性與領域分工等機制能否提升辯論品質與決策表現，而非建構能勝過市場的交易策略。因此，C、D 是否勝過一律看多，是交易策略的標準；它不能取代「這些設計條件之間是否有差異」這個問題。RQ2 檢驗 D 相對於 C 的差異是否取決於模型組合；RQ3 是平行的架構延伸，不涉及立場交換，檢驗領域分工相對於通才流程的差異。兩者都是受控比較，不論結果為正或負，都能回答在指定條件下哪一種設計有差異。

RQ2、RQ3 檢驗的是候選條件，不是 RQ1 結果已證實的原因；本節也沒有新增任何結果。若後續仍未觀察到改善，結論應是「在指定條件下沒有看

到改善」，而不是分工有用或無用的一般結論。上文「後續假說」段列出了其他可能的解釋，本研究並未將它們分開檢驗。

第四節　研究限制

一、資料有效性

九檔股票是以「資料取得容易」為主挑選的，沒有納入已下市的公司，所以有存活偏誤與事後選樣的風險。財報申報日、總經歷史版本與新聞時間戳記，控制了資料「何時可得」，但無法排除模型訓練時的記憶；匿名化之後仍保留數值、日期與產品線索。行情用的是下載當時的調整版本，也有事後被修訂的風險。新聞來源與數量會隨年份與個股而改變；排除 37 案的分析只是來源與覆蓋範圍的診斷，不能推廣成統一的新聞數量門檻。

二、實驗有效性

D 同時包含立場交換、隔離對手、強制引用與驗證重試，所以估計的是整套流程的差異，不是單獨立場交換的效果。預定呼叫次數相同，不代表重試次數、token 或運算量也相同。C、D 必須下注、而且可以用已到期的記憶；A、B 可以選持有、也沒有記憶，所以補充比較混合了好幾項差異（見下段）。每個案例只生成一次，所以觀察到的 C、D 分歧，也可能包含生成時的隨機雜訊。RQ1 屬於已見樣本的回溯比較：同一批樣本曾用於試跑與規則調整，因此不是事前確認性檢驗。

長期記憶的混淆。 A（單次判斷）與 B（多次取樣多數決，為自我一致性 (Wang et al., 2023) 的簡化版）代表不使用代理人架構的一般語言模型用法；記憶、反思與角色分工屬於代理人架構的組成 (Shinn et al., 2023; Park et al., 2023; Yu et al., 2024)，因此只有 C、D 設有長期記憶。主要比較 C 對 D，兩者都有記憶、條件對等，但記憶內容是各組自己的歷史，所以仍屬整套流程差異的一部分。A、B 對 C、D 的補充比較，同時混合了「有無辯論」與「有無記憶」，只能作為參考，不能把 C、D 相對於 A、B 的差異歸因於辯論。未來可做 C、D 都移除記憶的消融，以分開這兩項因素。

不同模型的能力組成與訓練記憶差異，很難完全分開；溫度或種子設成一樣，也不代表生成機制相同。領域切分可能遺失跨領域的互動，上層整

合也會受到輸入順序、長度與文風影響。模型輸出的多樣性或論述的豐富程度，不能直接當成績效改善的證據。

三、統計有效性

180 個案例共用 20 個分析日，持有期間也有重疊，而主要的 C／D 比較只有 16 個方向不一致的案例。依日期分組的信賴區間，只用來檢查相依性造成的影響，不能當成「一樣好」或「不比較差」的證據；最小可偵測差距也不是事前的檢定力規劃。因為事先沒有訂定「算作一樣好」的界線，所以不能用不顯著的結果，宣稱兩種流程相同。Sharpe 是用對齊後的日序列計算的，其觀測數 T 與案例數 180、日期分組數 20，三者不能互相替換。

四、外部有效性與可重現性

結果只限於九檔美國大型股、2021–2025 年，以及指定的模型與實驗規則，不能推廣到整個市場。Gemini 的比較用的是同一批案例，不是獨立重做；現有匯出紀錄也不能支持「兩個模型一字不差地讀到相同研究報告」的說法。FinBERT 的版本、完整的 Gemini 呼叫設定與行情調整版本，紀錄不夠完整，限制了精確重現。既有小樣本匿名探針的辨識率，也不代表全部 180 案。回測中的放空部位沒有計入借券費用，也沒有逐案檢查該股票在當時是否真的能被放空；行情使用含拆股與股利調整的價格，但沒有另外模擬股息對放空部位的影響。這些設定會讓放空的報酬偏樂觀；九檔都是大型股，影響可能較小，但本文沒有量化。紀錄完整度的現況整理於表 5-6；標示「部分具備」或「不完整」的項目，在補齊之前，本文的結果只能視為回溯比較，不能視為可完整重現的確認性結果。

表 5-6 可重現性紀錄的現況

紀錄項目	現況	說明
事前登記時間與實驗規則雜湊值	已核對	快照登記時間為 2026-10-02 05:35:33 UTC；實驗規則雜湊開頭為 `b1da80ee`。180 案均通過登記時間與樣本資格篩選
模型身分	部分具備	登記文件載明預期的模型權重指紋碼開頭為 030ee887880f…；實際執行的指紋碼須由逐步核對紀錄確認
180 案原始輸出與清單	已封存核對	180 份資料內容雜湊均符合 ID；3,960 筆決策紀錄皆有原始回應。已封存清單與 SHA-256，尚未作語意層逐句人工審核
計算程式版本	已核對計算版本	使用提交 `eb36a8a` 的 reporting 原始碼；statistics、backtest、splits 與該提交相同。此為歷史程式重算，不宣稱重新啟動原容器映像
配對日報酬序列	已保存重算	共 1,219 個交易日；重算 C ／ D Sharpe 為 0.5913 ／ 0.5384，McNemar $p = 0.2101$、LW $p = 0.8015$，與原表四捨五入後一致
長期記憶實際內容	邊界已核對	已核對 6,804 筆記憶之同股、同組、同實驗規則、期間、成本、守門後層與到期邊界，未發現違規；這不證明記憶對推理的語意影響
FinBERT 版本、Gemini 呼叫設定、行情調整版本	不完整	限制精確重現，已於上文說明

第六章　結論與建議

第一節　研究發現與對研究問題的回應

在本報告列出的既有 180 案回溯比較中，立場交換辯論（D）的方向準確率是 55.0%，固定立場辯論（C）是 58.3%；年化 Sharpe 分別是 0.54 與 0.59。D 相對於 C 的兩項差異，都沒有達到事先訂定的「優越」判準，因此目前的資料不支持「整套 D 流程優於整套 C 流程」。這並不代表兩組一樣好；而且 D 同時包含立場交換、隔離對手、強制引用與驗證重試，也不能把結果歸因於單一的「立場交換」因素。

另一項值得注意的結果是：C、D 的準確率與四組的 Sharpe，點估計都低於「一律看多」與同配置買進持有（數字見第五章第一節第三項）。相關的事後檢定未顯著，Sharpe 相對買進持有則尚未檢定；本樣本的點估計未超過這些簡單基準，但這不構成統計劣勢或一般性無效的證據。Gemini 3 Flash 的探索性重跑在同一批案例上呈現相同方向，但它不是獨立重做，不能視為跨模型穩健性的確認。案例觀察只是描述，不能用來判斷因果機制。

RQ2 的模型組合與 RQ3 的領域決策分工，仍然是後續設計，目前沒有任何實驗結果；它們檢驗的是兩個候選條件，並非已被證實的原因。C、D 未勝過簡單基準，不影響它們的價值：本研究的目的是比較不同辯論設計之間的差異，檢驗立場交換、模型異質性與領域分工等機制能否提升辯論品質與決策表現，而不是建構能勝過市場的交易策略；RQ3 是不涉及立場交換的平行延伸。既有結果的原始輸出與版本對應仍未全部補齊。因此，本專題目前可支持的貢獻，是呈現一個受限條件下的 C／D 回溯比較、如實報告未觀察到優越性的結果，並整理後續可檢驗的研究設計；尚不能宣稱已建立一般化的投資方法或完全可重現的評估框架。

2026 年 10 月 15 日重算補記。 從本機保存的 RQ1 快照透過 SQLite backup 建立隔離副本，以唯讀方式驗證 180 個登記案例與資料內容，再以歷史計算程式重算。兩端點 Holm 校正後的 p 值為 0.420227 與 0.8015，既有負面結果不變。證據包包含逐案資料、原始輸出、記憶、日面板、計算原始碼與完整性清單；來源副本的 SHA-256 在重算前後一致。此補件提高結果的可查核性，但不改變 RQ1 屬於回溯比較的性質。

第二節　應用與價值

一、可追溯的決策輔助

在應用上，本系統是一個投資研究流程原型：它把資料整理、正反論證、裁決理由與回測結果放在同一流程中，目標是讓使用者能追查建議依據，而不是只得到買賣訊號。由於現有紀錄仍有缺漏，而且績效沒有勝過簡單基準，本文不宣稱它已是有效的投資決策工具。在方法上，本研究透過預定呼叫次數對齊、規則登記、匿名化、版本鎖定與稽核紀錄，嘗試提高語言模型代理人比較的可追溯性。不過，同一批資料曾用於前導試跑與規則調整，所以本研究屬回溯比較，規則登記不能使其成為確認性驗證；預定呼叫次數相同，也不能排除實際運算量的差異。這套架構目前適合作為後續多代理人受控比較的研究原型。

二、多代理人系統設計

研究的價值也在於：讓不同的系統設計可以被清楚地比較。只是給代理人取不同的名字，不足以證明它們有用的差異；到底需不需要不同的模型、複雜的資訊適不適合交給專才處理、領域拆分有沒有好處，都應該用受控的結果與成本來回答。若後續RQ2、RQ3執行後仍未觀察到改善，這項研究提供的是「在指定條件下沒有看到改善」的紀錄，而不是「分工有用」或「可完整重現」的證據。

第三節　未來展望

一、不同時間尺度的穩健性

未來可以比較「每季／60日」與「每月／20日」兩種設定，檢驗結果在不同時間尺度下穩不穩，以及較短的尺度會不會減輕資訊整合的負擔。時間尺度的改變與領域分工是兩個不同的研究因素；每月／20日的比較會另外獨立設計，不併入本研究的180個季度案例。

二、模型、路由、消融與獨立樣本外檢驗

後續可以考慮更多模型、不同模型的裁決者、動態路由、動態辯論、領域加權、運算效率，以及不同的辯論輪數。其他延伸還包括：只讀自己、但不換立場的消融（拿掉「換立場」這一項，看效果是否還在；這直接對應D是整套流程的限制，是釐清D內部成分的下一步）、C、D都移除長期記憶的消融（分開「有無辯論」與「有無記憶」）、空頭與高波動時期的檢查、同一案例C組以不同種子重複執行，以及完整的汙染探針。需要學習參數或權重時，必須另外準備開發與驗證用的資料；最後要用新的期間或新的標的做獨立樣本外評估，不能在產生假說的同一批資料上，把探索結果改稱是確認性證據。

參考文獻

Araci, D. (2019). FinBERT: Financial sentiment analysis with pre-trained language models. arXiv preprint arXiv:1908.10063. https://doi.org/10.48550/arXiv.1908.10063.

Chen, W., Y. Su, J. Zuo, C. Yang, C. Yuan, C.-M. Chan, H. Yu, Y. Lu, Y.-H. Hung, C. Qian, Y. Qin, X. Cong, R. Xie, Z. Liu, M. Sun, and J. Zhou (2023). AgentVerse: Facilitating multi-agent collaboration and exploring emergent behaviors. arXiv preprint arXiv:2308.10848v3. https://arxiv.org/abs/2308.10848v3.

Chen, Y., G. Luo, Z. Wu, and L. Mou (2026). Multi-persona thinking for bias mitigation in large language models. In *Findings of the Association for Computational Linguistics: ACL 2026*, pp. 27895–27909.

Chowdhury, M. N., N. J. Beg, U. H. Khan, S. R. Raiyan, M. K. Hasan, and H. Mahmud (2026). Courtroom-style multi-agent debate with progressive RAG and role-switching for controversial claim verification. arXiv preprint arXiv:2603.28488v1. https://doi.org/10.48550/arXiv.2603.28488.

Corwin, S. A. and P. Schultz (2012). A simple way to estimate bid-ask spreads from daily high and low prices. *The Journal of Finance 67*(2), 719–760.

Dong, Z., X. Fan, and Z. Peng (2024). FNSPID: A comprehensive financial news dataset in time series. arXiv preprint arXiv:2402.06698. https://doi.org/10.48550/arXiv.2402.06698.

Du, Y., S. Li, A. Torralba, J. B. Tenenbaum, and I. Mordatch (2023). Improving factuality and reasoning in language models through multiagent debate. arXiv preprint arXiv:2305.14325. https://doi.org/10.48550/arXiv.2305.14325.

Gemma Team (2025). Gemma 3 technical report. arXiv preprint arXiv:2503.19786.

Glasserman, P. and C. Lin (2023). Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis. arXiv preprint arXiv:2309.17322. https://doi.org/10.48550/arXiv.2309.17322.

Herzog, S. M. and R. Hertwig (2009). The wisdom of many in one mind: Improving individual judgments with dialectical bootstrapping. *Psychological Science 20*(2), 231–

237.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics 6*(2), 65–70.

Huang, J., A. Alrassan, D. Harischandra, T. Wu, V. Skarich, and M. Hayes (2026). Multi-agent debate for explainable trading: Reasoning, consensus, and performance in simulated markets. arXiv preprint arXiv:2609.29701. https://doi.org/10.48550/arXiv.2609.29701.

Huang, J., X. Chen, S. Mishra, H. S. Zheng, A. W. Yu, X. Song, and D. Zhou (2024). Large language models cannot self-correct reasoning yet. In *International Conference on Learning Representations*.

Jobson, J. D. and B. M. Korkie (1981). Performance hypothesis testing with the sharpe and treynor measures. *The Journal of Finance 36*(4), 889–908.

Kong, Y., H. Lee, Y. Hwang, A. Lopez-Lira, B. Levy, D. Mehta, Q. Wen, C. Choi, Y. Lee, and S. Zohren (2026). Evaluating LLMs in finance requires explicit bias consideration. arXiv preprint arXiv:2602.14233v1. https://doi.org/10.48550/arXiv.2602.14233.

Ledoit, O. and M. Wolf (2008). Robust performance hypothesis testing with the sharpe ratio. *Journal of Empirical Finance 15*(5), 850–859.

Liang, T., Z. He, W. Jiao, X. Wang, Y. Wang, R. Wang, Y. Yang, Z. Tu, and S. Shi (2023). Encouraging divergent thinking in large language models through multi-agent debate. arXiv preprint arXiv:2305.19118v1. https://doi.org/10.48550/arXiv.2305.19118.

Liu, X.-Y., G. Wang, H. Yang, and D. Zha (2023). FinGPT: Democratizing internet-scale data for financial large language models. arXiv preprint arXiv:2307.10485. https://doi.org/10.48550/arXiv.2307.10485.

Liu, Z., S. Khajavi, G. Jiang, and X. Liu (2025). Uncertainty-aware role-switching debate: Improving truthfulness in large language models. OpenReview, https://openreview.net/forum?id=heYWeCpOlS.

Lopez-Lira, A. and Y. Tang (2023). Can ChatGPT forecast stock price movements? return predictability and large language models. arXiv preprint arXiv:2304.07619. https://doi.org/10.48550/arXiv.2304.07619.

Lord, C. G., M. R. Lepper, and E. Preston (1984). Considering the opposite: A corrective strategy for social judgment. *Journal of Personality and Social Psychology 47*(6), 1231–1243.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika 12*(2), 153–157.

Nosek, B. A., C. R. Ebersole, A. C. DeHaven, and D. T. Mellor (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences 115*(11), 2600–2606.

Park, J. S., J. C. O'Brien, C. J. Cai, M. R. Morris, P. Liang, and M. S. Bernstein (2023). Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology (UIST '23)*, pp. 1–22. arXiv:2304.03442.

Sharpe, W. F. (1994). The sharpe ratio. *The Journal of Portfolio Management 21*(1), 49–58.

Shinn, N., F. Cassano, E. Berman, A. Gopinath, K. Narasimhan, and S. Yao (2023). Reflexion: Language agents with verbal reinforcement learning. In *Advances in Neural Information Processing Systems*, Volume 36. arXiv:2303.11366.

Smit, A., P. Duckworth, N. Grinsztajn, T. D. Barrett, and A. Pretorius (2023). Should we be going MAD? a look at multi-agent debate strategies for LLMs. arXiv preprint arXiv:2311.17371. `https://doi.org/10.48550/arXiv.2311.17371`.

Wagenmakers, E.-J., R. Wetzels, D. Borsboom, H. L. J. van der Maas, and R. A. Kievit (2012). An agenda for purely confirmatory research. *Perspectives on Psychological Science 7*(6), 632–638.

Wang, J., J. Wang, B. Athiwaratkun, C. Zhang, and J. Zou (2024). Mixture-of-Agents enhances large language model capabilities. arXiv preprint arXiv:2406.04692v1. `https://arxiv.org/abs/2406.04692v1`.

Wang, X., J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou (2023). Self-consistency improves chain of thought reasoning in language models. In *International Conference on Learning Representations*.

Xiao, Y., E. Sun, D. Luo, and W. Wang (2024). TradingAgents: Multi-agents LLM financial trading framework. arXiv preprint arXiv:2412.20138. `https://doi.org/10.48550/arXiv.2412.20138`.

Yang, A., A. Li, B. Yang, et al. (2025). Qwen3 technical report. arXiv preprint arXiv:2505.09388.

Yang, H., B. Zhang, N. Wang, C. Guo, X. Zhang, L. Lin, J. Wang, T. Zhou, M. Guan, R. Zhang, and C. D. Wang (2024). FinRobot: An open-source ai agent platform for financial applications using large language models. arXiv preprint arXiv:2405.14767v2. https://arxiv.org/abs/2405.14767v2.

Yu, Y., H. Li, Z. Chen, Y. Jiang, Y. Li, D. Zhang, R. Liu, J. W. Suchow, and K. Khashanah (2024). FinMem: A performance-enhanced LLM trading agent with layered memory and character design. In *Proceedings of the AAAI Symposium Series*, Volume 3. arXiv:2311.13743.

Zhang, C., X. Liu, Z. Zhang, M. Jin, L. Li, Z. Wang, W. Hua, D. Shu, S. Zhu, X. Jin, S. Li, M. Du, and Y. Zhang (2024). When AI meets finance (StockAgent): Large language model-based stock trading in simulated real-world environments. arXiv preprint arXiv:2407.18957. https://doi.org/10.48550/arXiv.2407.18957.

Zhang, H., Z. Cui, J. Chen, X. Wang, Q. Zhang, Z. Wang, D. Wu, and S. Hu (2025). Stop overvaluing multi-agent debate – we must rethink evaluation and embrace model heterogeneity. arXiv preprint arXiv:2502.08788. https://doi.org/10.48550/arXiv.2502.08788.

Zheng, L., W.-L. Chiang, Y. Sheng, S. Zhuang, Z. Wu, Y. Zhuang, Z. Lin, Z. Li, D. Li, E. P. Xing, H. Zhang, J. E. Gonzalez, and I. Stoica (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. arXiv preprint arXiv:2306.05685v4. https://arxiv.org/abs/2306.05685v4.

本文僅供學術研究與教學使用，不構成任何投資建議。